

# Chapter 7: Bayesian Hypothesis Test

## 강의 목표

- ▶ 고전적 가설 검정의 이해
- ▶ 베이지안 가설 검정의 이해
  - ▶ One-side Test
  - ▶ Two-side Test
  - ▶ Multiple Hypotheses Test

# Classical Hypothesis Test

- ▶ Recall that classical hypothesis testing emphasizes the **p-value**:

# Classical Hypothesis Test

- ▶ Recall that classical hypothesis testing emphasizes the **p-value**: The probability (under  $H_0$ ) that a test statistic would take a value as (or more) favorable to  $H_a$  as the observed value of this test statistic.

# Classical Hypothesis Test

- ▶ Recall that classical hypothesis testing emphasizes the **p-value**: The probability (under  $H_0$ ) that a test statistic would take a value as (or more) favorable to  $H_a$  as the observed value of this test statistic.
- ▶ For example, given iid data  $x = x_1, \dots, x_n$  from a density  $f(x | \theta)$ , where  $-\infty < \theta < \infty$ , we might test  $H_0 : \theta \leq 0$  vs.  $H_a : \theta > 0$  using some test statistic  $T(X)$  (a function of the data).

# Classical Hypothesis Test

- ▶ Recall that classical hypothesis testing emphasizes the **p-value**: The probability (under  $H_0$ ) that a test statistic would take a value as (or more) favorable to  $H_a$  as the observed value of this test statistic.
- ▶ For example, given iid data  $x = x_1, \dots, x_n$  from a density  $f(x | \theta)$ , where  $-\infty < \theta < \infty$ , we might test  $H_0 : \theta \leq 0$  vs.  $H_a : \theta > 0$  using some test statistic  $T(X)$  (a function of the data).
- ▶ For Z-test:  $T(X)$  is standardized sample mean.

# Classical Hypothesis Test

- ▶ Then if we calculated  $T(x) = T^*$  for our observed data  $x$ , the p-value would be:

## Classical Hypothesis Test

- ▶ Then if we calculated  $T(x) = T^*$  for our observed data  $x$ , the p-value would be:

$$\begin{aligned} p\text{-value} &= \Pr(T(X) \geq T^* \mid \theta = 0) \\ &= \int_{T^*}^{\infty} f_T(t \mid \theta = 0) dt. \end{aligned}$$

where  $f_T(t \mid \theta)$  is the distribution of  $T(X)$ .



## Classical Hypothesis Test

- ▶ Then if we calculated  $T(x) = T^*$  for our observed data  $x$ , the p-value would be:

$$\begin{aligned} p\text{-value} &= \Pr(T(X) \geq T^* \mid \theta = 0) \\ &= \int_{T^*}^{\infty} f_T(t \mid \theta = 0) dt. \end{aligned}$$

where  $f_T(t \mid \theta)$  is the distribution of  $T(X)$ .

- ▶ This p-value is an average over  $T$  values (and thus sample values) that have not occurred and are unlikely to occur.

## Classical Hypothesis Test

- ▶ Then if we calculated  $T(x) = T^*$  for our observed data  $x$ , the p-value would be:

$$\begin{aligned} p\text{-value} &= \Pr(T(X) \geq T^* \mid \theta = 0) \\ &= \int_{T^*}^{\infty} f_T(t \mid \theta = 0) dt. \end{aligned}$$

where  $f_T(t \mid \theta)$  is the distribution of  $T(X)$ .

- ▶ This p-value is an average over  $T$  values (and thus sample values) that have not occurred and are unlikely to occur.
- ▶ Since the inference is based on “hypothetical” data rather than only the observed data, it violates the Likelihood Principle.

## Limitations of Classical Hypothesis Test

- ▶ The idea of conducting many **repeated tests** that motivate "Type I error" and "Type II error" probabilities is not sensible in situations where our study is not repeatable.

## Limitations of Classical Hypothesis Test

- ▶ The idea of conducting many **repeated tests** that motivate "Type I error" and "Type II error" probabilities is not sensible in situations where our study is not repeatable.
- ▶ Classical hypothesis testing mostly focus on "**Type I error**" rather than "Type II error". For some cases, "Type II error" is more important than "Type I error".

## Limitations of Classical Hypothesis Test

- ▶ The idea of conducting many **repeated tests** that motivate "Type I error" and "Type II error" probabilities is not sensible in situations where our study is not repeatable.
- ▶ Classical hypothesis testing mostly focus on "**Type I error**" rather than "Type II error". For some cases, "Type II error" is more important than "Type I error".
- ▶ Classical hypothesis testing cannot deal with multiple hypotheses. It can only test with **two** hypotheses.

# Bayesian Approach

- ▶ A simple approach to testing finds the posterior probabilities that  $\theta$  falls in the null and alternative regions.

# Bayesian Approach

- ▶ A simple approach to testing finds the posterior probabilities that  $\theta$  falls in the null and alternative regions.
- ▶ We first consider one-sided tests about  $\theta$  of the form:

$$H_0 : \theta \leq c \quad \text{vs.} \quad H_a : \theta > c$$

for some constant  $c$ , where  $-\infty < \theta < \infty$ .

# Bayesian Approach

- ▶ A simple approach to testing finds the posterior probabilities that  $\theta$  falls in the null and alternative regions.
- ▶ We first consider one-sided tests about  $\theta$  of the form:

$$H_0 : \theta \leq c \quad \text{vs.} \quad H_a : \theta > c$$

for some constant  $c$ , where  $-\infty < \theta < \infty$ .

- ▶ We define  $\Theta_0$  and  $\Theta_1$ .



# Bayesian Approach

- ▶ A simple approach to testing finds the posterior probabilities that  $\theta$  falls in the null and alternative regions.
- ▶ We first consider one-sided tests about  $\theta$  of the form:

$$H_0 : \theta \leq c \quad \text{vs.} \quad H_a : \theta > c$$

for some constant  $c$ , where  $-\infty < \theta < \infty$ .

- ▶ We define  $\Theta_0$  and  $\Theta_1$ .
- ▶  $\Theta_0$  is the set of  $\theta$ -values such that  $H_0$  is true.

## Bayesian Approach

- ▶ A simple approach to testing finds the posterior probabilities that  $\theta$  falls in the null and alternative regions.
- ▶ We first consider one-sided tests about  $\theta$  of the form:

$$H_0 : \theta \leq c \quad \text{vs.} \quad H_a : \theta > c$$

for some constant  $c$ , where  $-\infty < \theta < \infty$ .

- ▶ We define  $\Theta_0$  and  $\Theta_1$ .
- ▶  $\Theta_0$  is the set of  $\theta$ -values such that  $H_0$  is true.
- ▶  $\Theta_1$  is the set of  $\theta$ -values such that  $H_1$  is true.

## Prior/Posterior Probabilities

- ▶ We specify prior probabilities for  $\theta$  such that

## Prior/Posterior Probabilities

- ▶ We specify prior probabilities for  $\theta$  such that

$$\pi_0 := \Pr(-\infty < \theta \leq c) = P(\theta \in \Theta_0)$$

$$\pi_1 := \Pr(c < \theta \leq \infty) = P(\theta \notin \Theta_0).$$

## Prior/Posterior Probabilities

- ▶ We specify prior probabilities for  $\theta$  such that

$$\pi_0 := \Pr(-\infty < \theta \leq c) = P(\theta \in \Theta_0)$$

$$\pi_1 := \Pr(c < \theta \leq \infty) = P(\theta \notin \Theta_0).$$

- ▶ We specify posterior probabilities for  $\theta$  such that

## Prior/Posterior Probabilities

- ▶ We specify prior probabilities for  $\theta$  such that

$$\pi_0 := \Pr(-\infty < \theta \leq c) = P(\theta \in \Theta_0)$$

$$\pi_1 := \Pr(c < \theta \leq \infty) = P(\theta \notin \Theta_0).$$

- ▶ We specify posterior probabilities for  $\theta$  such that

$$p_0 | x := \Pr(-\infty < \theta \leq c | x) = P(\theta \in \Theta_0 | x)$$

$$p_1 | x := \Pr(c < \theta \leq \infty | x) = P(\theta \notin \Theta_0 | x).$$

## Posterior Odds

- Posterior probabilities for  $\theta$  can be re-written as:

$$p_0 | x := \int_{\Theta_0} \pi(\theta | x) = \frac{\int_{\Theta_0} f(x | \theta) \pi(\theta) d\theta}{\int_{\Theta_0} f(x | \theta) \pi(\theta) d\theta + \int_{\Theta_1} f(x | \theta) \pi(\theta) d\theta}$$

$$p_1 | x := \int_{\Theta_1} \pi(\theta | x) = \frac{\int_{\Theta_1} f(x | \theta) \pi(\theta) d\theta}{\int_{\Theta_0} f(x | \theta) \pi(\theta) d\theta + \int_{\Theta_1} f(x | \theta) \pi(\theta) d\theta}$$

- Note that the denominators are the same constant, not a function of  $\theta$ .
- Hence, the **posterior odds** is as follows:

$$\frac{p_0}{p_1} | x = \frac{\Pr(H_0 | x)}{\Pr(H_1 | x)} = \frac{\int_{\Theta_0} f(x | \theta) \pi(\theta) d\theta}{\int_{\Theta_1} f(x | \theta) \pi(\theta) d\theta}$$

## Prior/Posterior Odds

- ▶ Prior odds can be understood as in favor of  $H_0$  against  $H_a$

$$\text{Prior odds} = \frac{\pi_0}{\pi_1}$$



## Prior/Posterior Odds

- ▶ Prior odds can be understood as in favor of  $H_0$  against  $H_a$

$$\text{Prior odds} = \frac{\pi_0}{\pi_1}$$

- ▶ Posterior odds can be understood as in favor of  $H_0$  against  $H_a$

$$\text{Posterior odds} = \frac{p_0}{p_1} \mid x$$

## Prior/Posterior Odds

- ▶ Prior odds can be understood as in favor of  $H_0$  against  $H_a$

$$\text{Prior odds} = \frac{\pi_0}{\pi_1}$$

- ▶ Posterior odds can be understood as in favor of  $H_0$  against  $H_a$

$$\text{Posterior odds} = \frac{p_0}{p_1} \mid x$$

- ▶ A posterior odds may be **similar** to a prior odds because a posterior probability highly depends on its prior probability.

## Prior/Posterior Odds

- ▶ Prior odds can be understood as in favor of  $H_0$  against  $H_a$

$$\text{Prior odds} = \frac{\pi_0}{\pi_1}$$

- ▶ Posterior odds can be understood as in favor of  $H_0$  against  $H_a$

$$\text{Posterior odds} = \frac{p_0}{p_1} \mid x$$

- ▶ A posterior odds may be **similar** to a prior odds because a posterior probability highly depends on its prior probability.
- ▶ Need a measure for the weight of evidence in favor of  $H_0$ .

# Bayes Factor

- ▶ The **Bayes Factor** provides a measure for comparison of two competing models, say  $M_1$  and  $M_2$ .
- ▶ It is similar to testing a “full model” vs. “reduced model” (with, e.g., a likelihood ratio test) in classical statistics.
- ▶ However, with the Bayes Factor, one model does not have to be **nested** within the other.
- ▶ Given a data set  $x = x_1, \dots, x_n$ , we compare models

$$M_1 : f_1(x \mid \theta_1) \quad \text{vs} \quad M_2 : f_2(x \mid \theta_2)$$

- ▶ We may specify prior distributions  $\pi_1(\theta_1)$  and  $\pi_2(\theta_2)$  that lead to prior probabilities for each model  $\Pr(M_1)$  and  $\Pr(M_2)$ .

## Bayes Factor

- ▶ If the prior model probabilities are equal, i.e.,  $\pi(M_1) = \pi(M_2)$ , then the Bayes Factor equals the posterior odds for  $M_1$ .

## Bayes Factor

- ▶ If the prior model probabilities are equal, i.e.,  $\pi(M_1) = \pi(M_2)$ , then the Bayes Factor equals the posterior odds for  $M_1$ .
- ▶ If  $\pi(M_1) = \pi(M_2)$  and the parameter spaces  $\Theta_1$  and  $\Theta_2$  are the same, then the Bayes Factor reduces to a likelihood ratio.

## Bayes Factor

- ▶ If the prior model probabilities are equal, i.e.,  $\pi(M_1) = \pi(M_2)$ , then the Bayes Factor equals the posterior odds for  $M_1$ .
- ▶ If  $\pi(M_1) = \pi(M_2)$  and the parameter spaces  $\Theta_1$  and  $\Theta_2$  are the same, then the Bayes Factor reduces to a likelihood ratio.

$$B(x) = \frac{\Pr(M_1 | x)}{\Pr(M_2 | x)} \times \frac{\pi(M_2)}{\pi(M_1)} = \frac{\Pr(x | M_1)}{\Pr(x | M_2)}$$

## Bayes Factor: Jeffreys Rule

- ▶ A Bayes Factor greater than 1 supports Model 1 over Model 2.



## Bayes Factor: Jeffreys Rule

- ▶ A Bayes Factor greater than 1 supports Model 1 over Model 2.
- ▶ Jeffreys proposed the following rules:

## Bayes Factor: Jeffreys Rule

- ▶ A Bayes Factor greater than 1 supports Model 1 over Model 2.
- ▶ Jeffreys proposed the following rules:
  - ▶ If  $B(x) \geq 1$ , Model 1 supported.
  - ▶ If  $\sqrt{0.1} \leq B(x) \leq 1$ , minimal evidence against Model 1
  - ▶ If  $0.1 \leq B(x) \leq \sqrt{0.1}$ , substantial evidence against Model 1
  - ▶ If  $0.01 \leq B(x) \leq 0.1$ , strong evidence against Model 1
  - ▶ If  $B(x) \leq 0.01$ , decisive evidence against Model 1

## Bayes Factor: Weighted Likelihood Ratio

- ▶ Suppose that  $H_0 : \theta \in \Theta_0$  vs.  $H_a : \theta \in \Theta_1$ .

## Bayes Factor: Weighted Likelihood Ratio

- ▶ Suppose that  $H_0 : \theta \in \Theta_0$  vs.  $H_a : \theta \in \Theta_1$ .
- ▶ Bayes Factor can be restated as

## Bayes Factor: Weighted Likelihood Ratio

- ▶ Suppose that  $H_0 : \theta \in \Theta_0$  vs.  $H_a : \theta \in \Theta_1$ .
- ▶ Bayes Factor can be restated as

$$B(x) = \frac{p_0/p_1}{\pi_0/\pi_1} = \frac{\int_{\Theta_0} f(x | \theta) \pi(\theta) d\theta / \int_{\Theta_0} \pi(\theta) d\theta}{\int_{\Theta_1} f(x | \theta) \pi(\theta) d\theta / \int_{\Theta_1} \pi(\theta) d\theta}$$

## Bayes Factor: Weighted Likelihood Ratio

- ▶ Suppose that  $H_0 : \theta \in \Theta_0$  vs.  $H_a : \theta \in \Theta_1$ .
- ▶ Bayes Factor can be restated as

$$\begin{aligned} B(x) &= \frac{p_0/p_1}{\pi_0/\pi_1} = \frac{\int_{\Theta_0} f(x | \theta) \pi(\theta) d\theta / \int_{\Theta_0} \pi(\theta) d\theta}{\int_{\Theta_1} f(x | \theta) \pi(\theta) d\theta / \int_{\Theta_1} \pi(\theta) d\theta} \\ &= \frac{\int_{\Theta_0} f(x | \theta) \frac{\pi(\theta)}{\int_{\Theta_0} \pi(\theta) d\theta} d\theta}{\int_{\Theta_1} f(x | \theta) \frac{\pi(\theta)}{\int_{\Theta_1} \pi(\theta) d\theta} d\theta} \end{aligned}$$

## Bayes Factor: Weighted Likelihood Ratio

- ▶ Suppose that  $H_0 : \theta \in \Theta_0$  vs.  $H_a : \theta \in \Theta_1$ .
- ▶ Bayes Factor can be restated as

$$\begin{aligned} B(x) &= \frac{p_0/p_1}{\pi_0/\pi_1} = \frac{\int_{\Theta_0} f(x | \theta) \pi(\theta) d\theta / \int_{\Theta_0} \pi(\theta) d\theta}{\int_{\Theta_1} f(x | \theta) \pi(\theta) d\theta / \int_{\Theta_1} \pi(\theta) d\theta} \\ &= \frac{\int_{\Theta_0} f(x | \theta) \frac{\pi(\theta)}{\int_{\Theta_0} \pi(\theta) d\theta} d\theta}{\int_{\Theta_1} f(x | \theta) \frac{\pi(\theta)}{\int_{\Theta_1} \pi(\theta) d\theta} d\theta} \\ &= \frac{\mathbb{E}_{\Theta_0} [f(x | \theta)]}{\mathbb{E}_{\Theta_1} [f(x | \theta)]}. \end{aligned}$$

## Bayes Factor: Weighted Likelihood Ratio

- ▶ Bayes Factor 의 각 요소는 확률밀도함수

$$\pi(\theta)I(\theta \in \Theta_i) / \int_{\Theta_i} \pi(\theta)d\theta$$

를 사용한 우도함수 (likelihood function)의 가중 평균이다.



## Bayes Factor: Weighted Likelihood Ratio

- ▶ Bayes Factor 의 각 요소는 확률밀도함수

$$\pi(\theta)I(\theta \in \Theta_i) / \int_{\Theta_i} \pi(\theta) d\theta$$

를 사용한 우도함수 (likelihood function)의 가중 평균이다.

- ▶ 즉, 가중우도비(weighted likelihood ratio)라고 할 수 있다.

## Bayes Factor: Classical Likelihood Ratio

- ▶ 만약  $\Theta_0 = \{\theta_0\}$ ,  $\Theta_1 = \{\theta_1\}$ 이면,

## Bayes Factor: Classical Likelihood Ratio

- ▶ 만약  $\Theta_0 = \{\theta_0\}$ ,  $\Theta_1 = \{\theta_1\}$ 이면,

$$B(x) = f(x \mid \theta_0)/f(x \mid \theta_1).$$

since  $p_0/p_1 = \pi_0 f(x \mid \theta_0)/\pi_1 f(x \mid \theta_1)$ .

## Bayes Factor: Classical Likelihood Ratio

- ▶ 만약  $\Theta_0 = \{\theta_0\}$ ,  $\Theta_1 = \{\theta_1\}$ 이면,

$$B(x) = f(x | \theta_0) / f(x | \theta_1).$$

since  $p_0/p_1 = \pi_0 f(x | \theta_0) / \pi_1 f(x | \theta_1)$ .

- ▶ 가중치 (weight)는  $\pi(\theta)I(\theta \in \Theta_i) / \int_{\Theta_i} \pi(\theta)d\theta = I(\theta \in \Theta_i)$ 가 되므로, 이 상황에서는 bayes factor는 likelihood ratio와 동일하다.

## Example

Suppose we have a random variable that produces either a success or a failure. We want to compare a model  $M_1$  where the probability of success is  $\theta = \frac{1}{2}$ , and another model  $M_2$  where  $\theta$  is unknown and we take a prior distribution for  $\theta$  that is uniform on  $[0, 1]$ . We take a sample of  $n = 200$ , and find  $x = 115$  successes and  $n - x = 85$  failures. The likelihood can be calculated according to the binomial distribution:

## Example

Suppose we have a random variable that produces either a success or a failure. We want to compare a model  $M_1$  where the probability of success is  $\theta = \frac{1}{2}$ , and another model  $M_2$  where  $\theta$  is unknown and we take a prior distribution for  $\theta$  that is uniform on  $[0, 1]$ . We take a sample of  $n = 200$ , and find  $x = 115$  successes and  $n - x = 85$  failures. The likelihood can be calculated according to the binomial distribution:

$$L(\theta \mid x) = \binom{200}{115} \theta^{115} (1 - \theta)^{85}.$$

## Example: Bayesian Hypothesis Test

Thus, we have

## Example: Bayesian Hypothesis Test

Thus, we have

$$P(X = 115 \mid M_1) = \binom{200}{115} \left(\frac{1}{2}\right)^{200} = 0.005956,$$

but



## Example: Bayesian Hypothesis Test

Thus, we have

$$P(X = 115 \mid M_1) = \binom{200}{115} \left(\frac{1}{2}\right)^{200} = 0.005956,$$

but

$$P(X = 115 \mid M_2) = \int_0^1 \binom{200}{115} \theta^{115} (1 - \theta)^{85} d\theta = \frac{1}{201} = 0.004975.$$

## Example: Bayesian Hypothesis Test

Thus, we have

$$P(X = 115 \mid M_1) = \binom{200}{115} \left(\frac{1}{2}\right)^{200} = 0.005956,$$

but

$$P(X = 115 \mid M_2) = \int_0^1 \binom{200}{115} \theta^{115} (1 - \theta)^{85} d\theta = \frac{1}{201} = 0.004975.$$

The ratio is then 1.197, which is **barely worth mentioning** even if it points very slightly towards  $M_1$ .

## Example: Classical Hypothesis Test

- ▶ P-value: the probability of getting 115 or more successes from a sample of 200 if  $\theta = \frac{1}{2}$  is 0.014, and as a two-tailed test of getting a figure as extreme as or more extreme than 115 is 0.028.

$$\Pr(X \geq 115 \mid \theta = 0.5) \approx \Pr\left(Z \geq \frac{(115 - 100)}{\sqrt{50}}\right) = 0.017$$

## Example: Classical Hypothesis Test

- ▶ P-value: the probability of getting 115 or more successes from a sample of 200 if  $\theta = \frac{1}{2}$  is 0.014, and as a two-tailed test of getting a figure as extreme as or more extreme than 115 is 0.028.

$$\Pr(X \geq 115 \mid \theta = 0.5) \approx \Pr\left(Z \geq \frac{(115 - 100)}{\sqrt{50}}\right) = 0.017$$

- ▶ Classical hypothesis test would yield significant results at the 5% significance level.

## Example: Classical Hypothesis Test

- ▶ P-value: the probability of getting 115 or more successes from a sample of 200 if  $\theta = \frac{1}{2}$  is 0.014, and as a two-tailed test of getting a figure as extreme as or more extreme than 115 is 0.028.

$$\Pr(X \geq 115 \mid \theta = 0.5) \approx \Pr\left(Z \geq \frac{(115 - 100)}{\sqrt{50}}\right) = 0.017$$

- ▶ Classical hypothesis test would yield significant results at the 5% significance level.
- ▶ However Bayes factor hardly considers this to be an extreme result.

## Example: Remarks

- ▶ Note that a non-uniform prior could result in a Bayes factor that is more in agreement with the frequentist hypothesis test.

## Example: Remarks

- ▶ Note that a non-uniform prior could result in a Bayes factor that is more in agreement with the frequentist hypothesis test.
- ▶ A classical likelihood-ratio test would have found the MLE for  $\theta$  ( $M_2: \theta = \frac{115}{200} = 0.575$ ) where

$$P(X = 115 \mid M_2) = \binom{200}{115} \theta^{115} (1 - \theta)^{85} = 0.056991.$$

## Example: Remarks

- ▶ Note that a non-uniform prior could result in a Bayes factor that is more in agreement with the frequentist hypothesis test.
- ▶ A classical likelihood-ratio test would have found the MLE for  $\theta$  ( $M_2: \theta = \frac{115}{200} = 0.575$ ) where

$$P(X = 115 \mid M_2) = \binom{200}{115} \theta^{115} (1 - \theta)^{85} = 0.056991.$$

- ▶ That gives a Bayes factor of 0.1045, and so pointing towards  $M_2$ .



## Another Example

$X \mid \theta \sim N(\theta, 1)$ 일 때 검정

## Another Example

$X \mid \theta \sim N(\theta, 1)$ 일 때 검정

$$H_0 : \theta = 1, \quad \text{vs} \quad H_a : \theta = -1$$

## Another Example

$X | \theta \sim N(\theta, 1)$ 일 때 검정

$$H_0 : \theta = 1, \quad \text{vs} \quad H_a : \theta = -1$$

과 위 검정에서 가설을 바꾼 다음을 고려해보자.

$$H_0 : \theta = -1, \quad \text{vs} \quad H_a : \theta = 1$$

## Bayes Factor: $H_0$ vs $H_1$

$x = 00$ 이 관측되었을 때,  $H_0$ 와  $H_1$ 의 검정에 대한 베이즈 상수를 구하면

## Bayes Factor: $H_0$ vs $H_1$

$x = 00$ 이 관측되었을 때,  $H_0$ 와  $H_1$ 의 검정에 대한 베이지 상수를 구하면

$$B(x) = \exp \left[ -\frac{1}{2} ((0 - 1)^2 - (0 + 1)^2) \right] = e^0 = 1.$$

## Bayes Factor: $H_0$ vs $H_1$

$x = 0$ 이 관측되었을 때,  $H_0$ 와  $H_1$ 의 검정에 대한 베이지 상수를 구하면

$$B(x) = \exp \left[ -\frac{1}{2} ((0 - 1)^2 - (0 + 1)^2) \right] = e^0 = 1.$$

즉  $x = 0$ 의 관측치는 어느 가설도 지지 하는 않는다.

## Bayes Factor: $H_1$ vs $H_0$

$x = 00$ 이 관측되었을 때,  $H_1$ 와  $H_0$ 의 검정에 대한 베이즈 상수를 구하면

## Bayes Factor: $H_1$ vs $H_0$

$x = 00$ 이 관측되었을 때,  $H_1$ 와  $H_0$ 의 검정에 대한 베이즈 상수를 구하면

$$B(x) = \exp \left[ -\frac{1}{2} ((0+1)^2 - (0-1)^2) \right] = e^0 = 1.$$



## Bayes Factor: $H_1$ vs $H_0$

$x = 0$ 이 관측되었을 때,  $H_1$ 와  $H_0$ 의 검정에 대한 베이지 상수를 구하면

$$B(x) = \exp \left[ -\frac{1}{2} ((0+1)^2 - (0-1)^2) \right] = e^0 = 1.$$

귀무가설과 대립가설을 바꾸더라도,  $x = 0$ 의 관측치는 어느 가설도 지지 하는 않으며 똑같은 베이지 상수를 가진다.

## Classical Hypothesis Test: $H_0$ vs $H_1$

$x = 0$ 이 관측되었을 때  $H_0$ 와  $H_1$ 의 검정에 대한 유의확률 (p-value)를 구하면

$$\text{p-value} = \Pr(X < 0 \mid X \sim N(1, 1)) = 0.1587.$$

즉  $x = 0$ 는 주어진 귀무가설에서 극단적인 케이스는 아니다.

## Classical Hypothesis Test: $H_1$ vs $H_0$

$x = 0$ 이 관측되었을 때  $H_1$ 와  $H_0$ 의 검정에 대한 유의확률 (p-value)를 구하면

$$\text{p-value} = \Pr(X > 0 \mid X \sim N(-1, 1)) = 0.1587.$$

귀무가설과 대립가설을 바꾸더라도,  $x = 0$ 는 같은 p-value를 가진다.

일반적으로 생각하는 좋은 테스트란, 주어진 데이터를 통해 귀무가설과 대립가설의 순서와 관계 없이 일관성있게 결론을 주는 것이라고 생각된다. 이 경우 Bayesian & Classical hypothesis test는 같은 결과를 준다.

## Bayes Factor: $H_0$ vs $H_1$

$x = 1$ 이 관측되었을 때  $H_0$ 와  $H_1$ 의 검정에 대한 베이즈 상수를 구하면

$$B(x) = \exp \left[ -\frac{1}{2} ((1-1)^2 - (1+1)^2) \right] = e^2 = 7.38.$$

즉  $x = 1$ 의 관측치는 귀무가설 ( $\theta = 1$ )을 강력히 지지한다.

## Bayes Factor: $H_1$ vs $H_0$

$x = 10$ 이 관측되었을 때  $H_1$ 와  $H_0$ 의 검정에 대한 베이즈 상수를 구하면

$$B(x) = \exp \left[ -\frac{1}{2} ((1+1)^2 - (1-1)^2) \right] = e^{-2} = 1/7.38.$$

즉  $x = 1$ 의 관측치는 대립가설 ( $\theta = 1$ )을 강력히 지지한다.

## Classical Hypothesis Test: $H_0$ vs $H_1$

$x = 1$ 이 관측되었을 때  $H_0$ 와  $H_1$ 의 검정에 대한 유의확률 (p-value)를 구하면

$$\text{p-value} = \Pr(X < 1 \mid X \sim N(1, 1)) = 0.50.$$

즉  $x = 0$ 는 주어진 귀무가설에서 극단적인 케이스는 아니다.

## Classical Hypothesis Test: $H_1$ vs $H_0$

$x = 10$ 이 관측되었을 때  $H_1$ 와  $H_0$ 의 검정에 대한 유의확률 (p-value)를 구하면

$$\text{p-value} = \Pr(X > 1 \mid X \sim N(-1, 1)) = 0.025.$$

귀무가설과 대립가설을 바꾸면, 전혀 관계없는 p-value를 가진다.  
하지만 그 결론은 모순이 아니다.

Baeyesian test 가설의 순서에 의존 하지 않지만, classical test는 귀무가설과 대립가설의 순서에 결론이 바뀔 수 있다.

## Another Example

$X \mid \theta \sim N(\theta, 1)$ 일 때 검정



## Another Example

$X \mid \theta \sim N(\theta, 1)$ 일 때 검정

$$H_0 : \theta = 2, \quad \text{vs} \quad H_a : \theta = -2$$

## Another Example

$X \mid \theta \sim N(\theta, 1)$ 일 때 검정

$$H_0 : \theta = 2, \quad \text{vs} \quad H_a : \theta = -2$$

과 위 검정에서 가설을 바꾼 다음을 고려해보자.

$$H_0 : \theta = -2, \quad \text{vs} \quad H_a : \theta = 2$$

## Bayes Factor: $H_0$ vs $H_1$

$x = 00$ 이 관측되었을 때,  $H_0$ 와  $H_1$ 의 검정에 대한 베이즈 상수를 구하면

## Bayes Factor: $H_0$ vs $H_1$

$x = 00$ 이 관측되었을 때,  $H_0$ 와  $H_1$ 의 검정에 대한 베이즈 상수를 구하면

$$B(x) = \exp \left[ -\frac{1}{2} ((0 - 2)^2 - (0 + 2)^2) \right] = e^0 = 1.$$

## Bayes Factor: $H_0$ vs $H_1$

$x = 0$ 이 관측되었을 때,  $H_0$ 와  $H_1$ 의 검정에 대한 베이즈 상수를 구하면

$$B(x) = \exp \left[ -\frac{1}{2} ((0 - 2)^2 - (0 + 2)^2) \right] = e^0 = 1.$$

즉  $x = 0$ 의 관측치는 어느 가설도 지지 하는 않는다.

## Bayes Factor: $H_1$ vs $H_0$

$x = 00$ 이 관측되었을 때,  $H_1$ 와  $H_0$ 의 검정에 대한 베이즈 상수를 구하면

## Bayes Factor: $H_1$ vs $H_0$

$x = 00$ 이 관측되었을 때,  $H_1$ 와  $H_0$ 의 검정에 대한 베이즈 상수를 구하면

$$B(x) = \exp \left[ -\frac{1}{2} ((0+2)^2 - (0-2)^2) \right] = e^0 = 1.$$

## Bayes Factor: $H_1$ vs $H_0$

$x = 0$ 이 관측되었을 때,  $H_1$ 와  $H_0$ 의 검정에 대한 베이지 상수를 구하면

$$B(x) = \exp \left[ -\frac{1}{2} ((0+2)^2 - (0-2)^2) \right] = e^0 = 1.$$

귀무가설과 대립가설을 바꾸더라도,  $x = 0$ 의 관측치는 어느 가설도 지지 하는 않으며 똑같은 베이지 상수를 가진다.



## Classical Hypothesis Test: $H_0$ vs $H_1$

$x = 0$ 이 관측되었을 때  $H_0$ 와  $H_1$ 의 검정에 대한 유의확률 (p-value)를 구하면

$$\text{p-value} = \Pr(X < 0 \mid X \sim N(2, 1)) \approx 0.025.$$

$$\text{p-value} = \Pr(X > 0 \mid X \sim N(-2, 1)) \approx 0.025.$$

귀무가설과 대립가설을 바꾸면,  $x = 0$ 의 관측치는 모순된 결과를 도출한다.

## Bayesian One-sided Test

- Suppose that

$$H_0 : \theta \leq \theta_0, \quad \text{vs} \quad H_a : \theta > \theta_0.$$

- Suppose that

$$X_1, X_2, \dots, X_n \mid \theta \sim_{iid} N(\theta, \sigma^2).$$

- Then,

$$\Theta_0 = (-\infty, \theta_0], \quad \Theta_0 = (\theta_0, -\infty).$$

## Bayesian One-sided Test

- ▶ Suppose that the prior distribution is  $\pi(\theta) \propto 1$ ,
- ▶ Then  $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$  has the following distribution:

$$\bar{X} \sim N(\theta, \sigma^2/n).$$

- ▶ Posterior distribution is

$$P(\theta \mid X_1, X_2, \dots, X_n) \sim N(\bar{x}, \sigma^2/n).$$

where  $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$

## Bayesian Test for Normal Case

- Find the posterior probability for  $H_0$ :

$$P(H_0 \mid X_1, \dots, X_n) = P(\theta \leq \theta_0 \mid \bar{x}) = \Phi \left( \frac{\theta_0 - \bar{x}}{\sigma/\sqrt{n}} \right).$$

where  $\Phi(\cdot)$  is the CDF of standard normal distribution.

## Classical Test for Normal Case

- Find the p-value of the classical test.

$$P(\bar{X} \geq \bar{x} \mid \theta_0) = 1 - \Phi\left(\frac{\bar{x} - \theta_0}{\sigma/\sqrt{n}}\right).$$

- Hence the p-value is the same as the posterior probability for  $H_0$ .

## Example

W라고 하는 새로운 입자의 질량을 알아보고자 한다. 여러 번의 독립적인 측정을 통하여 얻은 입자의 평균 질량은 82.1이고 추정오차는 1.7이었다. 입자의 질량이 83.0보다 큰 지 검정하고자 한다. 이 경우 다음 가설을 세울 수 있다:

$$H_0 : \theta \leq 83.0 \quad \text{vs} \quad H_1 : \theta > 83.0.$$

## Example: Bayesian Approach

충분한 수의 독립적인 반복 측정이 이루어졌다고 보고 분산  $\sigma^2/n = 1.7^2$ 이 알려진 경우로 간주하자. 베이지안 검정을 위해 먼저  $\theta$ 에 대한 사전분포로 무정보 사전분포  $\pi(\theta) = 1$ 을 가정하면  $\theta$ 의 사후분포는  $N(82.1, 1.7^2)$ 이며,  $H_0$ 의 사후확률은  $P_0 = \Phi((83.0 - 82.1)/1.7) = 0.7017$ 이다.  $H_0$ 와  $H_1$ 의 위험도를 동등하게 본다면  $0.7017 > 0.5$ 이므로 귀무가설을 채택한다.

## Example: Another Bayesian Approach

W라는 입자의 성질에 대한 물리적 이론에 의하면 이 입자의 질량은 82.4이며 추정오차는 1.1이라고 한다. 이 물리적 이론으로부터 얻은 정보를 사전정보로 사용하여  $\theta$ 의 사전분포로  $N(82.4, 1.1^2)$ 을 가정할 수 있다. 사전분포로부터  $H_0$ 의 사전확률을 구하면

$$\pi_0 = \Pr(\theta \leq 83.0) = \Phi((83.0 - 82.4)/1.1) = 0.7088.$$

그리고  $\pi_1 = 1 - \pi_0 = 0.2912$ 이므로  $H_0$ 와  $H_1$ 의 사전비는 2.64이다.



## Example: Another Bayesian Approach

사전분포와 관측치로부터  $\theta$ 의 사후분포를 구하면

$$\theta \sim N(82.3, 0.92^2)$$

- ▶ The posterior expectation:

$$\frac{\frac{\delta}{\tau^2} + \frac{n\bar{x}}{\sigma^2}}{\frac{1}{\tau^2} + \frac{n}{\sigma^2}} = \frac{\sigma^2}{\sigma^2 + n\tau^2}\delta + \frac{n\tau^2}{\sigma^2 + n\tau^2}\bar{x}.$$

- ▶ The posterior variance:

$$\left( \frac{1}{\tau^2} + \frac{n}{\sigma^2} \right)^{-1}$$

## Example: Another Bayesian Approach

그러므로 사후 확률은 다음과 같다.

$$p_0 = P(\theta \leq 83.0 \mid \bar{x}) = \Phi((83.0 - 82.3)/0.92) = 0.7764,$$

$$p_1 = 1 - p_0 = 0.2236.$$

으로 사후비는 3.47이다.  $H_0$  와  $H_1$ 의 위험도를 동등하게 본다면 귀무가설을 채택할 것이다. 그런데 이 경우 베이즈 상수 (Bayes factor)는  $B(x) = 3.47/2.64 = 1.43$ 으로 귀무가설에 사후 지지도가 큰 주원인은 사전 지지도가 크기 때문이며, 자료가 주는 지지도는 1.43으로 사전 지지도에 비하여 미미함을 알 수있다.

## Bayesian One-sided Test for Beta Case

- ▶ Suppose that

$$H_0 : \theta \leq \theta_0, \quad \text{vs} \quad H_a : \theta > \theta_0.$$

- ▶ Suppose that

$$X \mid \theta \sim_{iid} \text{Bin}(n, \theta).$$

- ▶ Suppose that the prior distribution is  $\text{Beta}(a, b)$ .
- ▶ Then the posterior distribution is  $\text{Beta}(a + x, b + n - x)$ .

## Bayesian Test for Beta Case

- Find the posterior probability for  $H_0$ :

$$P(\theta \leq \theta_0 | x) = \int_0^{\theta_0} \frac{\Gamma(a+b+n)}{\Gamma(a+x)\Gamma(b+n-x)} \theta^{a+x-1} (1-\theta)^{b+n-x} d\theta$$

## Classical Test for Beta Case

- Find the p-value of the classical test.

$$P(\bar{X} \geq \bar{x} \mid \theta_0) \approx 1 - \Phi \left( \frac{\bar{x} - \theta_0}{\sqrt{\theta_0(1 - \theta_0)/n}} \right).$$

## Example

어느 도시의 시장을 선출하는 선거에서 두 후보 A와 B가 경쟁하고 있다. 최근 신문에 발표된 여론조사에 의하면 100명의 랜덤으로 선택된 선거권자들 중 53명이 A 후보를 지지하고 47명은 B 후보를 지지한다고 한다. 전체 선거권자들 중 A 후보를 지지하는 사람들의 비율을  $\theta$ 라 할 때  $\theta$ 에 대해 균일 사전분포를 가정하고 다음을 검정하자.

$$H_0 : \theta \leq 0.5 \quad \text{vs} \quad H_1 : \theta > 0.5$$

## Example: Bayesian Approach

$n = 100, x = 53, a = 1, b = 1$ 인 경우이므로,

## Example: Bayesian Approach

$n = 100, x = 53, a = 1, b = 1$ 인 경우이므로,  $\theta$ 의 사후분포는



## Example: Bayesian Approach

$n = 100, x = 53, a = 1, b = 1$ 인 경우이므로,  $\theta$ 의 사후분포는  $Beta(54, 48)$  이다.

## Example: Bayesian Approach

$n = 100, x = 53, a = 1, b = 1$ 인 경우이므로,  $\theta$ 의 사후분포는  $Beta(54, 48)$  이다.

$$p_0 = \Pr(\theta \leq 0.5 \mid x) = \Pr(\theta \leq 0.5 \mid \theta \sim Beta(54, 48)) = 0.275$$

## Example: Bayesian Approach

$n = 100, x = 53, a = 1, b = 1$ 인 경우이므로,  $\theta$ 의 사후분포는  $Beta(54, 48)$  이다.

$$p_0 = \Pr(\theta \leq 0.5 \mid x) = \Pr(\theta \leq 0.5 \mid \theta \sim Beta(54, 48)) = 0.275$$

따라서,  $p_1 = 1 - p_0 = 0.725$ .

## Example: Bayesian Approach

$n = 100, x = 53, a = 1, b = 1$ 인 경우이므로,  $\theta$ 의 사후분포는  $Beta(54, 48)$  이다.

$$p_0 = \Pr(\theta \leq 0.5 \mid x) = \Pr(\theta \leq 0.5 \mid \theta \sim Beta(54, 48)) = 0.275$$

따라서,  $p_1 = 1 - p_0 = 0.725$ . 베타분포에 대한 정규근사를 사용하면  $Beta(54, 48) \approx N(0.529, 0.049^2)$  이므로

## Example: Bayesian Approach

$n = 100, x = 53, a = 1, b = 1$ 인 경우이므로,  $\theta$ 의 사후분포는  $Beta(54, 48)$  이다.

$$p_0 = \Pr(\theta \leq 0.5 \mid x) = \Pr(\theta \leq 0.5 \mid \theta \sim Beta(54, 48)) = 0.275$$

따라서,  $p_1 = 1 - p_0 = 0.725$ . 베타분포에 대한 정규근사를 사용하면  $Beta(54, 48) \approx N(0.529, 0.049^2)$  이므로

$$p_0 = \Pr(\theta \leq 0.5 \mid \theta \sim N(0.529, 0.049^2)) = \Phi\left(\frac{0.5 - 0.529}{0.049}\right) = 0.277$$

## Example: Bayesian Approach

$n = 100, x = 53, a = 1, b = 1$ 인 경우이므로,  $\theta$ 의 사후분포는  $Beta(54, 48)$  이다.

$$p_0 = \Pr(\theta \leq 0.5 \mid x) = \Pr(\theta \leq 0.5 \mid \theta \sim Beta(54, 48)) = 0.275$$

따라서,  $p_1 = 1 - p_0 = 0.725$ . 베타분포에 대한 정규근사를 사용하면  $Beta(54, 48) \approx N(0.529, 0.049^2)$  이므로

$$p_0 = \Pr(\theta \leq 0.5 \mid \theta \sim N(0.529, 0.049^2)) = \Phi\left(\frac{0.5 - 0.529}{0.049}\right) = 0.277$$

따라서  $p_1 = 0.723$ .

## Example: Bayesian Approach

$n = 100, x = 53, a = 1, b = 1$ 인 경우이므로,  $\theta$ 의 사후분포는  $Beta(54, 48)$  이다.

$$p_0 = \Pr(\theta \leq 0.5 \mid x) = \Pr(\theta \leq 0.5 \mid \theta \sim Beta(54, 48)) = 0.275$$

따라서,  $p_1 = 1 - p_0 = 0.725$ . 베타분포에 대한 정규근사를 사용하면  $Beta(54, 48) \approx N(0.529, 0.049^2)$  이므로

$$p_0 = \Pr(\theta \leq 0.5 \mid \theta \sim N(0.529, 0.049^2)) = \Phi\left(\frac{0.5 - 0.529}{0.049}\right) = 0.277$$

따라서  $p_1 = 0.723$ . 베타 사후분포를 시용했을 때와 유사한 값을 얻는다.

## Example: Bayesian Conclusion

전체 모집단에서 A 후보의 지지율이 50% 이상일 사후확률은 약 72%이므로  $H_1$ 이  $H_0$ 보다 약 2.57배 더 높은 가능성을 지닌다.  
관측된 A 후보의 지지도 53%는 당선 기준 50% 보다 약간 큰 정도이지만 당선될 ( $\theta > 0.5$ ) 사후확률은 72.3%로 상당히 크다.  
이는 표본크기가 커서 추정오차가 작기 때문이다.



## Example: Classical Approach

Classical hypothesis test를 시행하면

## Example: Classical Approach

Classical hypothesis test를 시행하면

$$\text{p-value} = P(\bar{X} \geq \bar{x} \mid \theta_0) \approx 1 - \Phi \left( \frac{0.530 - 0.5}{\sqrt{1/4 \times 1/100}} \right) = 0.274.$$

## Example: Classical Approach

Classical hypothesis test를 시행하면

$$\text{p-value} = P(\bar{X} \geq \bar{x} \mid \theta_0) \approx 1 - \Phi \left( \frac{0.530 - 0.5}{\sqrt{1/4 \times 1/100}} \right) = 0.274.$$

이 경우, 관측값들이  $H_0$ 를 기각하는데 큰 증거가 되지 못한다.

## Bayesian Two-sided Test

- Suppose that

$$H_0 : \theta = \theta_0, \quad \text{vs} \quad H_a : \theta \neq \theta_0.$$

## Bayesian Two-sided Test

- ▶ Suppose that

$$H_0 : \theta = \theta_0, \quad \text{vs} \quad H_a : \theta \neq \theta_0.$$

- ▶ Suppose that

$$X_1, X_2, \dots, X_n \mid \theta \sim_{iid} N(\theta, \sigma^2).$$

## Bayesian Two-sided Test

- ▶ Suppose that

$$H_0 : \theta = \theta_0, \quad \text{vs} \quad H_a : \theta \neq \theta_0.$$

- ▶ Suppose that

$$X_1, X_2, \dots, X_n \mid \theta \sim_{iid} N(\theta, \sigma^2).$$

- ▶ Then,

$$\Theta_0 = \{\theta_0\}, \quad \Theta_0^c = (-\infty, \infty) \setminus \{\theta_0\}.$$

## Bayesian Two-sided Test

- ▶ Suppose that the prior distribution is  $\pi(\theta) \propto 1$ ,

## Bayesian Two-sided Test

- ▶ Suppose that the prior distribution is  $\pi(\theta) \propto 1$ ,
- ▶ Then  $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$  has the following distribution:



## Bayesian Two-sided Test

- ▶ Suppose that the prior distribution is  $\pi(\theta) \propto 1$ ,
- ▶ Then  $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$  has the following distribution:

$$\bar{X} \sim N(\theta, \sigma^2/n).$$

## Bayesian Two-sided Test

- ▶ Suppose that the prior distribution is  $\pi(\theta) \propto 1$ ,
- ▶ Then  $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$  has the following distribution:

$$\bar{X} \sim N(\theta, \sigma^2/n).$$

- ▶ Posterior distribution is:

## Bayesian Two-sided Test

- ▶ Suppose that the prior distribution is  $\pi(\theta) \propto 1$ ,
- ▶ Then  $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$  has the following distribution:

$$\bar{X} \sim N(\theta, \sigma^2/n).$$

- ▶ Posterior distribution is:

$$P(\theta \mid X_1, X_2, \dots, X_n) \sim N(\bar{x}, \sigma^2/n).$$

where  $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$

## Bayesian Test for Normal Case

- Find the posterior probability for  $H_0$ :

## Bayesian Test for Normal Case

- Find the posterior probability for  $H_0$ :

$$P(\theta = \theta_0 \mid \bar{x}) = 0.$$

## Bayesian Test for Normal Case

- ▶ Find the posterior probability for  $H_0$ :

$$P(\theta = \theta_0 \mid \bar{x}) = 0.$$

- ▶ 이 경우 사후 확률이 0이므로, 항상  $H_0$ 이 기각되므로, 좋은 테스트라고 할 수 없다.

## Bayesian Test for Normal Case

- ▶ Find the posterior probability for  $H_0$ :

$$P(\theta = \theta_0 \mid \bar{x}) = 0.$$

- ▶ 이 경우 사후 확률이 0이므로, 항상  $H_0$ 이 기각되므로, 좋은 테스트라고 할 수 없다.
- ▶ 그래서 유의미한 테스트를 할 수 있게 만들어 주는, prior distribution 을 찾도록 한다.

## Prior Distribution for Two-sided Test

- ▶ 베이지안 검정에서는 이를 피하기 위해 다음과 같은 연속과 이산의 합성 사전분포를 가정한다.



## Prior Distribution for Two-sided Test

- ▶ 베이저안 검정에서는 이를 피하기 위해 다음과 같은 연속과 이산의 합성 사전분포를 가정한다.

$$\pi(\theta) = \begin{cases} \pi_0 & \text{if } \theta = \theta_0, \\ (1 - \pi_0)g(\theta) & \text{if } \theta \neq \theta_0. \end{cases}$$

where  $g(\theta)$  is any probability density function.

## Prior Distribution for Two-sided Test

- ▶ 베이지안 검정에서는 이를 피하기 위해 다음과 같은 연속과 이산의 합성 사전분포를 가정한다.


$$\pi(\theta) = \begin{cases} \pi_0 & \text{if } \theta = \theta_0, \\ (1 - \pi_0)g(\theta) & \text{if } \theta \neq \theta_0. \end{cases}$$

where  $g(\theta)$  is any probability density function.

- ▶ 귀무가설에서 지정하는 한 점에서만 확률  $\pi_0$ 를 배정하고, 나머지 확률  $\pi_1 = 1 - \pi_0$ 를  $\theta_0$ 를 제외한 나머지 연속 구간에 밀도함수  $g(\theta)$ 에 따라 재배분하는 것이다.

## Prior Distribution for Two-sided Test

- ▶ 만약  $g(\theta)$ 가 정규분포의 density function이라면, 다음과 같은 사전 분포를 찾을 수 있다.



## Posterior Distribution for Two-sided Test

- ▶ The posterior distribution is as follows:

## Posterior Distribution for Two-sided Test

- ▶ The posterior distribution is as follows:

$$\Pr(\theta \mid x) = \frac{\pi_0 f(\bar{x} \mid \theta_0) I(\theta = \theta_0) + \pi_1 g(\theta) f(\bar{x} \mid \theta) I(\theta \neq \theta_0)}{m(\bar{x})}$$

## Posterior Distribution for Two-sided Test

- ▶ The posterior distribution is as follows:

$$\Pr(\theta | x) = \frac{\pi_0 f(\bar{x} | \theta_0) I(\theta = \theta_0) + \pi_1 g(\theta) f(\bar{x} | \theta) I(\theta \neq \theta_0)}{m(\bar{x})}$$

where

$$m(\bar{x}) = \pi_0 f(x | \theta_0) + \int_{\theta \neq \theta_0} \pi_1 g(\theta) f(\bar{x} | \theta) d\theta.$$

## Posterior Distribution for Two-sided Test

- ▶ The posterior distribution is as follows:

$$\Pr(\theta | x) = \frac{\pi_0 f(\bar{x} | \theta_0) I(\theta = \theta_0) + \pi_1 g(\theta) f(\bar{x} | \theta) I(\theta \neq \theta_0)}{m(\bar{x})}$$

where

$$m(\bar{x}) = \pi_0 f(x | \theta_0) + \int_{\theta \neq \theta_0} \pi_1 g(\theta) f(\bar{x} | \theta) d\theta.$$

- ▶ Note that the second term is:

$$\int_{\theta \neq \theta_0} \pi_1 g(\theta) f(\bar{x} | \theta) d\theta = \int \pi_1 g(\theta) f(\bar{x} | \theta) d\theta.$$

since  $g(\theta_0) = 0$ .

# Bayes Factor

- ▶ Posterior probability for the null hypothesis:



# Bayes Factor

- Posterior probability for the null hypothesis:

$$p_0 = \Pr(H_0 \mid \bar{x}) = \frac{\pi_0 f(\bar{x} \mid \theta_0)}{m(\bar{x})}.$$

# Bayes Factor

- ▶ Posterior probability for the null hypothesis:

$$p_0 = \Pr(H_0 \mid \bar{x}) = \frac{\pi_0 f(\bar{x} \mid \theta_0)}{m(\bar{x})}.$$

- ▶ Posterior probability for the alternative hypothesis:

# Bayes Factor

- ▶ Posterior probability for the null hypothesis:

$$p_0 = \Pr(H_0 \mid \bar{x}) = \frac{\pi_0 f(\bar{x} \mid \theta_0)}{m(\bar{x})}.$$

- ▶ Posterior probability for the alternative hypothesis:

$$p_1 = \Pr(H_1 \mid \bar{x}) = \frac{\pi_1 \int g(\theta) f(\bar{x} \mid \theta) d\theta}{m(\bar{x})}.$$

# Bayes Factor

- ▶ Posterior probability for the null hypothesis:

$$p_0 = \Pr(H_0 \mid \bar{x}) = \frac{\pi_0 f(\bar{x} \mid \theta_0)}{m(\bar{x})}.$$

- ▶ Posterior probability for the alternative hypothesis:

$$p_1 = \Pr(H_1 \mid \bar{x}) = \frac{\pi_1 \int g(\theta) f(\bar{x} \mid \theta) d\theta}{m(\bar{x})}.$$

- ▶ Bayes Factor:

# Bayes Factor

- ▶ Posterior probability for the null hypothesis:

$$p_0 = \Pr(H_0 \mid \bar{x}) = \frac{\pi_0 f(\bar{x} \mid \theta_0)}{m(\bar{x})}.$$

- ▶ Posterior probability for the alternative hypothesis:

$$p_1 = \Pr(H_1 \mid \bar{x}) = \frac{\pi_1 \int g(\theta) f(\bar{x} \mid \theta) d\theta}{m(\bar{x})}.$$

- ▶ Bayes Factor:

$$B(x) = \frac{p_0/p_1}{\pi_0/\pi_1} = \frac{f(\bar{x} \mid \theta_0)}{\int g(\theta) f(\bar{x} \mid \theta) d\theta}.$$

## Bayes Factor with Mixed Normal Prior

- ▶ Suppose that  $g(\theta)$  is mixed Normal distribution  $N(\theta_0, \sigma_0^2)$ .
- ▶ Then,

$$\bar{X} \sim N(\theta_0, \sigma^2/n).$$

- ▶ Hence

$$\int g(\theta) f(\bar{x} | \theta) d\theta = \frac{1}{\sqrt{2\pi(\sigma^2/n + \sigma_0^2)}} \exp \left\{ -\frac{(\bar{x} - \theta)^2}{2(\sigma^2/n + \sigma_0^2)} \right\}.$$

## Bayes Factor with Mixed Normal Prior

► Bayes Factor:

$$\begin{aligned} B(x) &= \frac{f(\bar{x} \mid \theta_0)}{\int g(\theta) f(\bar{x} \mid \theta) d\theta} \\ &= \sqrt{\frac{\sigma^2/n + \sigma_0^2}{\sigma^2/n}} \exp \left\{ -\frac{(\bar{x} - \theta)^2}{2(\sigma^2/n + \sigma_0^2)} \right\} \\ &= \sqrt{1 + \frac{\sigma_0^2}{\sigma^2/n}} \exp \left\{ -\frac{(\bar{x} - \theta)^2}{2\sigma^2/n} \left( 1 - \frac{\sigma^2/n}{\sigma^2/n + \sigma_0^2} \right) \right\} \\ &= \sqrt{1 + \frac{\sigma_0^2}{\sigma^2/n}} \exp \left\{ -\frac{1}{2} z^2 \left( 1 - \frac{\sigma^2/n}{\sigma^2/n + \sigma_0^2} \right) \right\} \end{aligned}$$

## Bayes Factor with Mixed Normal Prior

- ▶ 사전정보의 양을 한 개의 표본이 주는 정보의 양과 동일하게 여겨  $\sigma_0^2 = \sigma^2$ 이라 놓으면,

$$B(x) = \sqrt{1+n} \exp\left(-\frac{1}{2}z^2 \frac{n}{n+1}\right).$$

- ▶ 베이지 상수는 변수  $z$ 이외에도 샘플수  $n$ 에도 의존하고 있다.
- ▶ 반면 classical test는  $z$ 에만 변하고 샘플 수에는 영향을 받지 않는다 ( $n$ 은  $z$ 값 만 변화 시킨다).
- ▶  $n$ 이 커지면 커질 수록 베이지 상수도 증가하고, 귀무가설 ( $H_0$ )의 posterior probability가 증가한다.



## Hypothesis Test for Binomial Case

- ▶ Suppose that  $X \mid \theta \sim B(n, \theta)$ .
- ▶ Consider

$$H_0 : \theta = \theta_0 \quad \text{vs} \quad H_1 : \theta \neq \theta_0.$$

- ▶ Prior Distribution for  $\theta$ :

$$\pi(\theta) = \begin{cases} \pi_0 & \theta = \theta_0 \\ (1 - \pi_0)g(\theta) & , \theta \neq \theta_0 \end{cases}$$

where  $g(\theta)$ 는  $Beta(\alpha, \beta)$ 의 확률밀도함수이다.

## Hypothesis Test for Binomial Case

- Bayes Factor:

$$B(x) = \frac{f(x | \theta_0)}{\int f(x | \theta)g(\theta)d\theta}$$

- Let  $m_1(x) = \int f(x | \theta)g(\theta)d\theta$  be the density function for  $x$ .

$$\begin{aligned} m_1(x) &= \int_0^1 \binom{n}{x} \theta^x (1-\theta)^{n-x} \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} \theta^{\alpha-1} (1-\theta)^{\beta-1} d\theta \\ &= \binom{n}{x} \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} \int_0^1 \theta^{\alpha+x-1} (1-\theta)^{\beta+n-x-1} d\theta \\ &= \binom{n}{x} \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} \frac{\Gamma(\alpha+x)\Gamma(\beta+n-x)}{\Gamma(\alpha+\beta+n)} \end{aligned}$$

## Hypothesis Test for Binomial Case

► Bayes Factor:

$$\begin{aligned} B(x) &= \frac{\binom{n}{x} \theta_0^x (1 - \theta_0)^{n-x}}{\binom{n}{x} \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} \frac{\Gamma(\alpha+x)\Gamma(\beta+n-x)}{\Gamma(\alpha+\beta+n)}} \\ &= \frac{\theta_0^x (1 - \theta_0)^{n-x}}{\frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} \frac{\Gamma(\alpha+x)\Gamma(\beta+n-x)}{\Gamma(\alpha+\beta+n)}} \end{aligned}$$

## Example for the Two Sided Test

어떤 정밀 부품을 만드는 회사에서 부품의 불량률이 10%인지  
검정하고자 하여 생산 라인에서 50개의 부품을 랜덤 추출하여  
조사하니 3개가 불량이었다. 실제 불량률  $\theta$  에 대하여 사전분포로  
다음과 같이 가정하자.

$$\pi(\theta) = \begin{cases} 0.5 & \theta = 0.1 \\ 0.5g(\theta) & , \theta \neq 0.1 \end{cases}$$

$g(\theta)$ 는  $Beta(1, 9)$ 의 확률밀도함수이다.

## Example for the Two Sided Test

다음 가설을 검정해보자.

$$H_0 : \theta = 0.1 \quad \text{vs} \quad H_1 : \theta \neq 0.1.$$

## Example for the Two Sided Test

다음 가설을 검정해보자.

$$H_0 : \theta = 0.1 \quad \text{vs} \quad H_1 : \theta \neq 0.1.$$

$n = 50, x = 3, \alpha = 1, \beta = 9$  인 경우이므로

## Example for the Two Sided Test

다음 가설을 검정해보자.

$$H_0 : \theta = 0.1 \quad \text{vs} \quad H_1 : \theta \neq 0.1.$$

$n = 50, x = 3, \alpha = 1, \beta = 9$  인 경우이므로

$$m_1(x) = \binom{50}{3} \frac{\Gamma(10)}{\Gamma(1)\Gamma(9)} \frac{\Gamma(4)\Gamma(56)}{\Gamma(60)}.$$

## Example for the Two Sided Test

다음 가설을 검정해보자.

$$H_0 : \theta = 0.1 \quad \text{vs} \quad H_1 : \theta \neq 0.1.$$

$n = 50, x = 3, \alpha = 1, \beta = 9$  인 경우이므로

$$m_1(x) = \binom{50}{3} \frac{\Gamma(10)}{\Gamma(1)\Gamma(9)} \frac{\Gamma(4)\Gamma(56)}{\Gamma(60)}.$$

베이지스상수의 경우



## Example for the Two Sided Test

다음 가설을 검정해보자.

$$H_0 : \theta = 0.1 \quad \text{vs} \quad H_1 : \theta \neq 0.1.$$

$n = 50, x = 3, \alpha = 1, \beta = 9$  인 경우이므로

$$m_1(x) = \binom{50}{3} \frac{\Gamma(10)}{\Gamma(1)\Gamma(9)} \frac{\Gamma(4)\Gamma(56)}{\Gamma(60)}.$$

베이지스상수의 경우

$$B_x = \frac{f(x | \theta_0)}{m_1(x)} = \frac{(0.1)^3(0.9)^{47}}{\frac{\Gamma(10)}{\Gamma(1)\Gamma(9)} \frac{\Gamma(4)\Gamma(56)}{\Gamma(60)}} = 1.43.$$

## Example

이로부터  $p_0 = P(H_0 | x) = 0.588$  임을 알 수 있다.

## Example

이로부터  $p_0 = P(H_0 | x) = 0.588$  임을 알 수 있다.  $H_0$ 와  $H_1$ 의 위험도를 동등하게 본다면  $H_0 : \theta = 0.1$  를 채택할 것이다.

## Example

이로부터  $p_0 = P(H_0 | x) = 0.588$  임을 알 수 있다.  $H_0$ 와  $H_1$ 의 위험도를 동등하게 본다면  $H_0 : \theta = 0.1$  를 채택할 것이다. 그러나 이 경우 사후정보의  $H_0$ 에 대한 지지도가 아주 뚜렷하지는 않다.

## Hypothesis Test for Poisson Case

- ▶ Suppose that  $X_1, \dots, X_n \sim_{iid} \text{Poi}(\theta)$ .

## Hypothesis Test for Poisson Case

- ▶ Suppose that  $X_1, \dots, X_n \sim_{iid} \text{Poi}(\theta)$ .
- ▶ Consider

$$H_0 : \theta = \theta_0 \quad \text{vs} \quad H_1 : \theta \neq \theta_0.$$

## Hypothesis Test for Poisson Case

- ▶ Suppose that  $X_1, \dots, X_n \sim_{iid} Poi(\theta)$ .
- ▶ Consider

$$H_0 : \theta = \theta_0 \quad \text{vs} \quad H_1 : \theta \neq \theta_0.$$

- ▶ Prior distribution for  $\theta$ :

## Hypothesis Test for Poisson Case

- ▶ Suppose that  $X_1, \dots, X_n \sim_{iid} Poi(\theta)$ .
- ▶ Consider

$$H_0 : \theta = \theta_0 \quad vs \quad H_1 : \theta \neq \theta_0.$$

- ▶ Prior distribution for  $\theta$ :

$$\pi(\theta) = \begin{cases} 0.5 & , \theta = \theta_0 \\ 0.5g(\theta) & , \theta \neq \theta_0 \end{cases}$$

where  $g(\theta)$  is  $Gamma(\alpha, \beta)$  density function.



# Hypothesis Test for Poisson

► **Bayes Factor:**

$$B(x) = \frac{f(x \mid \theta_0)}{\int f(x \mid \theta)g(\theta)d\theta}, \quad \text{where } f(x \mid \theta) \sim \text{Poi}(n\theta)$$

# Hypothesis Test for Poisson

► **Bayes Factor:**

$$B(x) = \frac{f(x | \theta_0)}{\int f(x | \theta)g(\theta)d\theta}, \quad \text{where } f(x | \theta) \sim \text{Poi}(n\theta)$$

►  $m_1(x)$  be the density function for  $x$ .

$$m_1(x) = \int_0^\infty \frac{e^{-n\theta}(n\theta)^x}{x!} \frac{\beta^\alpha}{\Gamma(\alpha)} \theta^{\alpha-1} e^{-\beta\theta} d\theta$$

# Hypothesis Test for Poisson

► **Bayes Factor:**

$$B(x) = \frac{f(x | \theta_0)}{\int f(x | \theta)g(\theta)d\theta}, \quad \text{where } f(x | \theta) \sim \text{Poi}(n\theta)$$

►  $m_1(x)$  be the density function for  $x$ .

$$\begin{aligned} m_1(x) &= \int_0^\infty \frac{e^{-n\theta}(n\theta)^x}{x!} \frac{\beta^\alpha}{\Gamma(\alpha)} \theta^{\alpha-1} e^{-\beta\theta} d\theta \\ &= \frac{n^x \beta^\alpha}{x! \Gamma(\alpha)} \int_0^\infty \theta^{\alpha+x-1} d\theta \end{aligned}$$

# Hypothesis Test for Poisson

► **Bayes Factor:**

$$B(x) = \frac{f(x | \theta_0)}{\int f(x | \theta)g(\theta)d\theta}, \quad \text{where } f(x | \theta) \sim \text{Poi}(n\theta)$$

►  $m_1(x)$  be the density function for  $x$ .

$$\begin{aligned} m_1(x) &= \int_0^\infty \frac{e^{-n\theta}(n\theta)^x}{x!} \frac{\beta^\alpha}{\Gamma(\alpha)} \theta^{\alpha-1} e^{-\beta\theta} d\theta \\ &= \frac{n^x \beta^\alpha}{x! \Gamma(\alpha)} \int_0^\infty \theta^{\alpha+x-1} d\theta \\ &= \frac{n^x \beta^\alpha}{x! \Gamma(\alpha)} \frac{\Gamma(\alpha+x)}{(n+\beta)^{\alpha+x}} \end{aligned}$$

# Hypothesis Test for Poisson

► **Bayes Factor:**

$$B(x) = \frac{f(x | \theta_0)}{\int f(x | \theta)g(\theta)d\theta}, \quad \text{where } f(x | \theta) \sim \text{Poi}(n\theta)$$

►  $m_1(x)$  be the density function for  $x$ .

$$\begin{aligned} m_1(x) &= \int_0^\infty \frac{e^{-n\theta}(n\theta)^x}{x!} \frac{\beta^\alpha}{\Gamma(\alpha)} \theta^{\alpha-1} e^{-\beta\theta} d\theta \\ &= \frac{n^x \beta^\alpha}{x! \Gamma(\alpha)} \int_0^\infty \theta^{\alpha+x-1} d\theta \\ &= \frac{n^x \beta^\alpha}{x! \Gamma(\alpha)} \frac{\Gamma(\alpha+x)}{(n+\beta)^{\alpha+x}} \\ &= \frac{(\alpha+x-1)!}{x!(\alpha-1)!} \left( \frac{\beta}{n+\beta} \right)^\alpha \left( \frac{n}{n+\beta} \right)^x. \end{aligned}$$

## Hypothesis Test for Poisson

- ▶  $m_1(x)$  는 성공확률이  $\frac{\beta}{n+\beta}$  인 독립적인 베르누이 시행을  $\alpha$  번의 성공이 나올 때 까지 반복할 경우  $x$ 는 총 실패횟수를 나타낸다.

## Hypothesis Test for Poisson

- ▶  $m_1(x)$  는 성공확률이  $\frac{\beta}{n+\beta}$ 인 독립적인 베르누이 시행을  $\alpha$ 번의 성공이 나올 때 까지 반복할 경우  $x$ 는 총 실패횟수를 나타낸다.
- ▶ 그러므로,  $x = \sum_{i=1}^n x_i$ 의 주변분포는 다음과 같다.

$$NB\left(\alpha, \frac{\beta}{n+\beta}\right)$$

## Traffic Example

두 도시 에서 차량통행량 등 주위의 교통환경이 비슷한 교차로를 하나씩 선택하여 매주 발생한 교통사고 건수를 1년 동안 조사하였다. 첫 번째 도시에서는 직진 후 좌회전 신호를 사용하고 두 번째 도시에서는 좌회전 후 직진 신호를 사용한다. 교통사고 건수는 독립적으로 포아송 분포를따 른다고 가정한다. 교통통제 등의 이유로 조사를 할 수 없었던 기간을 제외하고 다음 표와 같은 조사 결과를 얻었다.



## Traffic Example

교통사고 건수	0	1	2	3	4	5	6	7
City 1의 사고 건수	7	14	13	8	4	2	2	0
City 2의 사고 건수	4	13	15	6	2	2	3	1

$$n_1 = 50, \quad \sum x_{1i} = 102, \quad \bar{x}_1 = 2.04$$

$$n_2 = 46, \quad \sum x_{2i} = 104, \quad \bar{x}_2 = 2.26$$

## Traffic Example: Prior Distribution

- ▶ 첫번째 도시의 교통사고 건수에만 집중하도록 하자.

## Traffic Example: Prior Distribution

- ▶ 첫번째 도시의 교통사고 건수에만 집중하도록 하자.
- ▶ 이제  $H_0 : \theta = 2$  vs  $H_1 : \theta \neq 2$  를 검정해 보자.

## Traffic Example: Prior Distribution

- ▶ 첫번째 도시의 교통사고 건수에만 집중하도록 하자.
- ▶ 이제  $H_0 : \theta = 2$  vs  $H_1 : \theta \neq 2$  를 검정해 보자.
- ▶ 첫번째 도시의 실제 평균 교통사고 건수  $\theta$  에 대한 사전 분포로  $Gamma(2, 1)$ 를 가정하자.

## Traffic Example: Prior Distribution

- ▶ 첫번째 도시의 교통사고 건수에만 집중하도록 하자.
- ▶ 이제  $H_0 : \theta = 2$  vs  $H_1 : \theta \neq 2$  를 검정해 보자.
- ▶ 첫번째 도시의 실제 평균 교통사고 건수  $\theta$  에 대한 사전 분포로  $Gamma(2, 1)$ 를 가정하자.

$$\pi(\theta) = \begin{cases} 0.5 & \theta = 2 \\ 0.5 g(\theta) & , \theta \neq 2 \end{cases}$$

$g(\theta)$ 는  $Gamma(2, 1)$  분포의 확률밀도함수이다.

## Traffic Example

►  $n = 50, x = \sum_{i=1}^{50} x_i = 102, \alpha = 2, \beta = 1.$

## Traffic Example

- ▶  $n = 50, x = \sum_{i=1}^{50} x_i = 102, \alpha = 2, \beta = 1.$
- ▶  $f(x | \theta_0)$ 는  $x = 102$ 에서  $Poi(2)$ 의 확률밀도함수.

## Traffic Example

- ▶  $n = 50, x = \sum_{i=1}^{50} x_i = 102, \alpha = 2, \beta = 1.$
- ▶  $f(x | \theta_0)$ 는  $x = 102$ 에서  $Poi(2)$ 의 확률밀도함수.
- ▶  $m_1(x)$ 는  $x = 102$ 에서  $NB(2, \frac{1}{51})$ 의 확률밀도함수.



## Traffic Example

- ▶  $n = 50, x = \sum_{i=1}^{50} x_i = 102, \alpha = 2, \beta = 1.$
- ▶  $f(x | \theta_0)$ 는  $x = 102$ 에서  $Poi(2)$ 의 확률밀도함수.
- ▶  $m_1(x)$ 는  $x = 102$ 에서  $NB(2, \frac{1}{51})$ 의 확률밀도함수.
- ▶ 베이즈 상수  $B_x = 7.364$ . 따라서  $P_0 = 0.8804$ 이다.  $H_0 : \theta = 2$ 에 대한 지지도가 매우 뚜렷하다.

## Posterior Probability for Multiple Hypotheses

- ▶ If there are multiple hypotheses e.g.,  $K$ , there are  $K$  distinct sets  $\Theta_0, \dots, \Theta_{K-1}$ .

## Posterior Probability for Multiple Hypotheses

- ▶ If there are multiple hypotheses e.g.,  $K$ , there are  $K$  distinct sets  $\Theta_0, \dots, \Theta_{K-1}$ .
- ▶ Then, Posterior probabilities for  $\theta$  are

$$p_i | x = \Pr(H_i | x) \propto \int_{\Theta_i} f(x | \theta) \pi(\theta) d\theta$$

## Example for Multiple Hypotheses Test

- ▶ 찬이의 IQ 점수는  $N(\theta, 100)$ 을 따른다고 한다.

## Example for Multiple Hypotheses Test

- ▶ 찬이의 IQ 점수는  $N(\theta, 100)$ 을 따른다고 한다.
- ▶ 찬이가 5번 IQ 테스트 ( $X_i$ )를 보았고, 평균점수가 115였다.

## Example for Multiple Hypotheses Test

- ▶ 찬이의 IQ 점수는  $N(\theta, 100)$ 을 따른다고 한다.
- ▶ 찬이가 5번 IQ 테스트 ( $X_i$ )를 보았고, 평균점수가 115였다.
- ▶ 이 경우  $X | \theta \sim N(\theta, 100/5)$ 이며  $\bar{x} = 115$ 의 관측치를 사용할 수 있겠다.  $\theta$ 의 사전분포를 정하는데, 우리나라 전체 인구의 IQ 점수는  $N(100, 15^2)$ 를 따른다고 알려져 있다.

## Example for Multiple Hypotheses Test

- ▶ 위의 표본분포와 사전분포로부터  $\theta$ 의 사후분포는  $N(113.78, 18.37^2)$ 이다.

## Example for Multiple Hypotheses Test

- ▶ 위의 표본분포와 사전분포로부터  $\theta$ 의 사후분포는  $N(113.78, 18.37^2)$ 이다.
- ▶ 찬이의 실제 IQ 점수  $\theta$ 가 전체 인구의 IQ 점수의 50백분위수보다 작은지, 50백분위수와 75백분위수 사이에 있는지, 75백분위수보다 높은지 알아보고자 한다.



## Example for Multiple Hypotheses Test

- ▶ 위의 표본분포와 사전분포로부터  $\theta$ 의 사후분포는  $N(113.78, 18.37^2)$ 이다.
- ▶ 찬이의 실제 IQ 점수  $\theta$ 가 전체 인구의 IQ 점수의 50백분위수보다 작은지, 50백분위수와 75백분 위수 사이에 있는지, 75백분 위수보다 높은지 알아보고자 한다.
- ▶ 전체 IQ 점수의 50, 75백분위수는 각각 100, 115.5이므로 관심있는 가설을 순서에 상관없이

## Example for Multiple Hypotheses Test

- ▶ 위의 표본분포와 사전분포로부터  $\theta$ 의 사후분포는  $N(113.78, 18.37^2)$ 이다.
- ▶ 찬이의 실제 IQ 점수  $\theta$ 가 전체 인구의 IQ 점수의 50백분위수보다 작은지, 50백분위수와 75백분위수 사이에 있는지, 75백분위수보다 높은지 알아보려고 한다.
- ▶ 전체 IQ 점수의 50, 75백분위수는 각각 100, 115.5이므로 관심있는 가설을 순서에 상관없이

$$H_0 : \theta < 100, \quad H_1 : 100 \leq \theta < 115.5, \quad H_2 : \theta \geq 115.5$$

로 두자.

## Example for Multiple Hypotheses Test

각 가설에 대한 사후확률을 구하면 다음과 같다.

$$p_0 = \Pr(H_0 \mid \bar{x}) = \Pr\left(Z < \frac{100 - 113.78}{18.37}\right) = 0.2266$$

## Example for Multiple Hypotheses Test

각 가설에 대한 사후확률을 구하면 다음과 같다.

$$p_0 = \Pr(H_0 \mid \bar{x}) = \Pr\left(Z < \frac{100 - 113.78}{18.37}\right) = 0.2266$$

$$\begin{aligned} p_1 &= \Pr(H_1 \mid \bar{x}) = \Pr\left(\frac{100 - 113.78}{18.37} \leq Z < \frac{115.5 - 113.78}{18.37}\right) \\ &= 0.3107 \end{aligned}$$

## Example for Multiple Hypotheses Test

각 가설에 대한 사후확률을 구하면 다음과 같다.

$$p_0 = \Pr(H_0 \mid \bar{x}) = \Pr\left(Z < \frac{100 - 113.78}{18.37}\right) = 0.2266$$

$$p_1 = \Pr(H_1 \mid \bar{x}) = \Pr\left(\frac{100 - 113.78}{18.37} \leq Z < \frac{115.5 - 113.78}{18.37}\right) \\ = 0.3107$$

$$p_2 = \Pr(H_2 \mid \bar{x}) = \Pr\left(Z > \frac{115.5 - 113.78}{18.37}\right) = 0.4627.$$

## Example for Multiple Hypotheses Test

각 가설에 대한 사후확률을 구하면 다음과 같다.

$$p_0 = \Pr(H_0 \mid \bar{x}) = \Pr\left(Z < \frac{100 - 113.78}{18.37}\right) = 0.2266$$

$$p_1 = \Pr(H_1 \mid \bar{x}) = \Pr\left(\frac{100 - 113.78}{18.37} \leq Z < \frac{115.5 - 113.78}{18.37}\right) \\ = 0.3107$$

$$p_2 = \Pr(H_2 \mid \bar{x}) = \Pr\left(Z > \frac{115.5 - 113.78}{18.37}\right) = 0.4627.$$

사후확률을 보면 찬이의 실제 IQ 점수 가 75백분 위수보다 높을 확률이 약 46%로 가장 크다.