

Chapter 10: Markov Chain Monte Carlo (MCMC)

강의 목표

- ▶ 사후분포의 근사적 추론(MCMC) 방법의 이해
 1. Gibbs Sampling
 2. Metropolis-Hastings
 3. Random Walk Metropolis
 4. Metropolis within Gibbs

Introduction

- ▶ Objectives: Estimate θ from posterior distribution.
- ▶ 사후분포의 유도는 베이지안 추론의 핵심이다.
- ▶ 하지만, 모수가 한개가 아닌 경우에는 사후분포의 유도가 어렵다.
- ▶ e.g.: $Normal(\mu, \sigma^2)$.

Example

- ▶ Suppose that

$$X_1, \dots, X_n \mid \mu, \sigma^2 \sim N(\mu, \sigma^2),$$

$$\mu \sim N(\mu_0, \sigma_0^2), \quad \sigma^2 \sim IG(a, b).$$

- ▶ In this case with $\mathbf{x} = (x_1, \dots, x_n)$, posterior distribution for (μ, σ^2) is following:

$$\sigma^{-n} \exp \left[-\frac{1}{2} \left\{ \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \mu)^2 + \frac{1}{\sigma_0^2} (\mu - \mu_0)^2 \right\} \right] (\sigma^2)^{-a-1} \exp(-b/\sigma^2)$$

- ▶ 위 분포는 흔히 알려진 분포가 아니며 결합 사후분포로부터의 표본생성도 간단치 않다.

Example

- ▶ Posterior for σ^2 given μ is:

$$\pi(\sigma^2 \mid \mathbf{x}, \mu) \sim IG \left(a + \frac{n}{2}, b + \frac{1}{2} \sum (x_i - \mu)^2 \right)$$

- ▶ Posterior for μ given σ^2 is Normal Distribution.
- ▶ If some parameters μ, σ^2 is provided, 사후분포로부터의 표본생성이 용이하다.
- ▶ 어떤 모수의 완전 조건부 사후분포(full conditional posterior distribution)란 그 모수를 제외한 다른 모든 모수가 주어졌을 때 해당 모수의 조건부 사후분포를 말한다.

Full Conditional Posterior Distribution

- ▶ $\theta = (\theta_1, \theta_2, \theta_3)$ 의 각 원소모수의 완전 조건부 사후분포

$$\pi(\theta_1, | x, \theta_2, \theta_3), \quad \pi(\theta_2, | x, \theta_1, \theta_3), \quad \pi(\theta_3, | x, \theta_1, \theta_2)$$

로부터의 표본추출이 용이한 경우를 생각해 보자.

- ▶ 이 경우 **깁스표본기법 (Gibbs Sampling Method)**의 알고리즘을 적용 시킬 수 있다.

Gibbs Sampling Method

- ▶ 겅스 표본기법 알고리즘은 조건에 들어가는 모수 값을 가장 최근의 값들로 대체하면서 차례대로 $(\theta_1, \theta_2, \theta_3)$ 을 완전 조건부 사후분포로부터 추출하는 것이다.

Step 0): $(\theta_1, \theta_2, \theta_3)$ 의 초기값 $(\theta_1^{(0)}, \theta_2^{(0)}, \theta_3^{(0)})$ 를 정한다.

Step 1): $\theta^{(1)} = (\theta_1^{(1)}, \theta_2^{(1)}, \theta_3^{(1)})$ 의 값 생성:

$$\theta_1^{(1)} \sim \pi(\theta_1 \mid x, \theta_2^{(0)}, \theta_3^{(0)})$$

$$\theta_2^{(1)} \sim \pi(\theta_2 \mid x, \theta_1^{(1)}, \theta_3^{(0)})$$

$$\theta_3^{(1)} \sim \pi(\theta_3 \mid x, \theta_2^{(1)}, \theta_1^{(1)})$$

Gibbs Sampling Method

Step 2): $\theta^{(2)} = (\theta_1^{(2)}, \theta_2^{(2)}, \theta_3^{(2)})$ 의 값 생성:

$$\theta_1^{(2)} \sim \pi(\theta_1 \mid x, \theta_2^{(1)}, \theta_3^{(1)})$$

$$\theta_2^{(2)} \sim \pi(\theta_2 \mid x, \theta_1^{(2)}, \theta_3^{(1)})$$

$$\theta_3^{(2)} \sim \pi(\theta_3 \mid x, \theta_2^{(2)}, \theta_3^{(2)})$$

Step m): $\theta^{(m)} = (\theta_1^{(m)}, \theta_2^{(m)}, \theta_3^{(m)})$ 의 값 생성:

$$\theta_1^{(m)} \sim \pi(\theta_1 \mid x, \theta_2^{(m-1)}, \theta_3^{(m-1)})$$

$$\theta_2^{(m)} \sim \pi(\theta_2 \mid x, \theta_1^{(m)}, \theta_3^{(m-1)})$$

$$\theta_3^{(m)} \sim \pi(\theta_3 \mid x, \theta_2^{(m)}, \theta_3^{(m)})$$


Gibbs Sampling Method

- ▶ Gibbs Sampling Method은 마코브 성질을 가짐.
- ▶ $\theta_1^{(m)}$ 은 가장 최근의 $(\theta_2^{(m-1)}, \theta_3^{(m-1)})$ 에만 의존할 뿐 그 이전의 (θ_2, θ_3) 값에는 의존하지 않는다.
- ▶ m 이 커짐에 따라 $\theta^{(m)}$ 은 $\pi(\theta | x)$ 로 수렴한다.

$$\theta^{(m)} \sim \pi(\theta | x)$$

- ▶ 따라서 m 시점 이후 N 개의 표본 $\theta^{(m+1)}, \dots, \theta^{(m+N)}$ 를 θ 의 사후표본으로 사용한다.

Gibbs Sampling Trace Plot)



Burn-in Time

- ▶ m : $\theta^{(i)}$ 의 분포가 $\pi(\theta | x)$ 로 수렴하기까지 걸리는 시간 (warm-up time, burn-in time)을 의미.
- ▶ N : 표본크기.

How to choose burn-in time m ?

- ▶ 표본의 경로그림(trace plot):

반복수(iteration number) vs 생성된 표본의값

- ▶ 경로그림이 어느 시점 이후에 초기치의 영향을 벗어나 서로 잘 겹쳐지는지, 그리고 이들 경로그림이 어느 시점 이후에 증가하거나 감소하지 않고 안정적인 패턴을 보이는지 확인하는 것

Properties of MCMC

- ▶ $(\theta^{(i)})$ 들이 서로 마코브체인으로 관련되어 있으므로 독립된 표본이 아니다.
- ▶ Convergence.

$$\hat{E}[\theta | x] = \frac{1}{N} \sum_{i=1}^N \theta^{(i)} \rightarrow E[\theta | x].$$

- ▶ Converging Speed: 수렴속도가 독립표본에 비하여 매우 느릴 수 있다.
- ▶ N개의 연관성 있는 표본이 갖는 정보는 독립된 표본들의 정보량이 적기 때문.

Properties of MCMC

- ▶ 수렴속도를 개선 하기 위해서 깃스 표본 알고리즘을 N 번 독립적으로수행때 어 $\theta_1^{(m)}, \dots, \theta_N^{(m)}$ 을 얻어 사용.
- ▶ 하지만 샘플을 얻는 시간 많이 걸리는 단점이 있음.
- ▶ **절충안**: 깃스 표본 알고리즘을 충분히 길게 돌린 후 m 번 이후에 k 간격을 두고 표본을 취하는 방법.
- ▶ $(\theta^{(m)}, \theta^{(m+k)}, \theta^{(m+2k)}, \dots, \theta^{(m+(N-1)k)})$ 을 추정에 사용하는 것이다.
- ▶ 왜냐하면 샘플들의 연관성이 약해져 대략 독립표본으로 간주할 수 있기 때문.

Example

- ▶ Suppose that




$$X_1, \dots, X_{10} \mid \mu, \sigma^2 \sim N(\mu, \sigma^2)$$

$$\mu \sim N(10, 5^2), \quad \sigma^2 \sim IG(0.5, 1).$$

- ▶ Let $x_1, \dots, x_{10} = (10, 13, 15, 11, 9, 18, 20, 17, 23, 21)$.
- ▶ Apply Gibbs sampling method for $\theta = (\mu, \sigma^2)$.



Example

- We first draw the trace plots ($m = 5, 15, 100$):



Example

- We first draw the trace plots given other parameters ($m = 5, 15, 100$):



Example

```
M=3000; m=500; mu0=10; sigsq0=25; a=0.5; b=1
x=c(10,13,15,11,9,18,20,17,23,21)
n=length(x); xbar=mean(x); var.x=var(x)
THETA=matrix(nrow=M ,ncol=2)
sigsq=var.x #initial value of sigsq
#####simulation#####
for(nsim in 1:M){
#generate mu
condpost.mu=(sigsq/n * mu0 +sigsq0*xbar)/(sigsq/n +sigsq0)
condpost.var=1/(1/sigsq0 +n/sigsq)
mu=rnorm(1, condpost.mu,sqrt(condpost.var))

#generate sigsq
condpost.a=a+n/2
condpost.b =b+1/2*((n-1) *var.x +n *(xbar -mu)^2)
sigsq =1/rgamma(1,condpost.a , condpost.b)

#save
THETA[nsim, ] = c(mu,sigsq)
}
#####End Simulation #####
```


Example

```
#### Trace Plot 1 ####
par(mfrow=c(1,3))
plot(THETA[1:5, ], type="n",
     xlab=expression(mu),ylab=expression(sigma^2))
lines(THETA[1:5, ],lty=2)
for(i in 1:5) text(THETA[i,1 ],THETA[i,2],i)
plot(THETA[1: 15, ] , type="n",
     xlab=expression(mu),ylab=expression(sigma^2))
lines(THETA[1:15, ], lty=2)
for(i in 1:15) text(THETA[i,1 ],THETA[i,2],i)
plot(THETA[1:100, ], type="n",
     xlab=expression(mu),ylab=expression(sigma^2))
lines(THETA[1:100, ], lty=2)
for(i in 1:100) text(THETA[i,1 ],THETA[i,2],i)

#### Trace Plot 2 ####
par(mfrow=c(1,2))
plot(THETA[,1], type="l", xlab=expression(mu), ylab="")
plot(THETA[,2], type="l", xlab=expression(sigma^2), ylab="")
```

Example

- ▶ 깃스 표본기법에서 μ, σ^2 의 주변 사후분포:



```
par(mfrow=c(1,2))  
plot(density(THETA[m:M,1]),xlab=expression(mu),ylab="marginal  
posterior",main="")  
plot(density(THETA[m:M,2]),xlab=expression(sigma^2),ylab="marginal  
posterior", main="")
```

Another Example: Why Gibbs Sampling

- ▶ $\mathbf{Y} = (Y_1, \dots, Y_5)$ 가 다음과 같은 모수를 갖는 다항분포를 따른다.

$$\mathbf{Y} \sim \text{Multi}(n, a_1\theta + b_1, a_2\theta + b_2, a_3\eta + b_3, a_4\eta + b_4, c(1 - \theta - \eta)),$$
$$a_i, b_i \leq 0, \quad 0 < c = 1 - \sum b_i = a_1 + a_2 = a_3 + a_4 < 1.$$

- ▶ 이 모형에서 미지의 모수는 (θ, η) 이며 $0 < \theta < 1$, $0 < \eta < 1$, $0 < \theta + \eta < 1$ 의 제한조건을 갖는다.
- ▶ 모수 (θ, η) 에 $\text{Dirichlet}(\alpha_1, \alpha_2, \alpha_3)$ 사전분포를 가정하면

$$\pi(\theta, \eta) \propto \theta^{\alpha_1-1} \eta^{\alpha_2-1} (1 - \theta - \eta)^{\alpha_3-1}$$

$$0 < \theta < 1, 0 < \eta < 1, 0 < \theta + \eta < 1$$

Another Example

- ▶ 사후밀도함수 (Posterior distribution):

$$\begin{aligned}\pi(\theta, \eta \mid \mathbf{y}) &\propto (a_1\theta + b_1)^{y_1}(a_2\theta + b_2)^{y_2}(a_3\theta + b_3)^{y_3}(a_4\theta + b_4)^{y_4} \\ &\times (c(1 - \theta - \eta))^{y_5}\theta^{\alpha_1-1}\eta^{\alpha_2-1}(1 - \theta - \eta)^{\alpha_3-1}\end{aligned}$$

- ▶ 사후밀도함수가 θ 와 η 의 복잡한 다항식이다.
- ▶ 그러므로 이 사후분포로부터 θ 와 η 의 사후기대치, 사후분산, 사후주변분포를 수리적으로 구하기는 어려움이 따른다.

Another Example

- ▶ 이 문제를 깁스 표본기법으로 해결하는 방법을 살펴보자.
- ▶ Let $\mathbf{X} = (X_1, \dots, X_9)$ and

$$X \sim \text{Multi}(n, a_1\theta, b_1, a_2\theta, b_2, a_3\eta, b_3, a_4\eta, b_4, c(1 - \theta - \eta)).$$

- ▶ 만약 \mathbf{X} 의 관측치 \mathbf{x} 가 주어진다면

$$\begin{aligned}\pi(\theta, \eta \mid \mathbf{x}) &\propto (a_1\theta)^{x_1} b_1^{x_2} (a_2\theta)^{x_3} (a_3\eta)^{x_5} b_3^{x_6} (a_4\eta)^{x_7} b_4^{x_8} (c(1 - \theta - \eta))^{x_9} \\ &\times \theta^{\alpha_1-1} \eta^{\alpha_2-1} (1 - \theta - \eta)^{\alpha_3-1} \\ &\propto \theta^{x_1+x_3+\alpha_1-1} \eta^{x_5+x_7+\alpha_2-1} (1 - \theta - \eta)^{x_9+\alpha_3-1}\end{aligned}$$

- ▶ 따라서 $\pi(\theta, \eta \mid \mathbf{x})$ 는 디리슈레(Dirichlet) 분포를 따르므로 사후추론이 매우 간편해진다.

Another Example

- ▶ X 와 Y 의 관계를 표로 나타내면 아래표와 같다.
- ▶ 5개의 관측가능한 범주 중 Y_1 은 첫 번째 범주의 도수이다.
- ▶ 범주의 확률이 $a_1\theta + b_1$ 이므로 이 사건은 두 가지 요인 A_1, B_1 에 의해 발생한다고 볼 수 있으며 $P(A_1) = a_1\theta, P(B_1) = b_q$.

키(cm)	Y_1		Y_2		Y_3		Y_4		Y_5	n
	X_1	X_2	X_3	X_4	X_5	X_6	X_7	X_8	X_9	n
체중(kg)	$a_1\theta$	b_1	$a_2\theta$	b_2	$a_3\eta$	b_3	$a_4\eta$	b_4	$c(1 - \theta - \eta)$	1

Table: X 와 Y 의 관계

Another Example

- ▶ A_1, B_1 에 대응하는 도수는 X_1, X_2 이다.
- ▶ X_1 과 X_2 의 확률이 모수에 의존하는 구조가 다르기 때문에 X_1 과 X_2 가 관측된다면 모수추정이 용이하겠지만 X_1, X_2 는 관측 불가능하고 단지 통합 도수 Y_1 만 가능할 뿐이다. 다른 범주에 대해서도 마찬가지이다.
- ▶ X 와 Y 의 관계를 살펴보면

$$X_1 + X_2 = Y_1, \quad X_3 + X_4 = Y_2,$$

$$X_5 + X_6 = Y_3, \quad X_7 + X_8 = Y_4,$$

$$X_9 = Y_5.$$

Another Example

- ▶ $X_2 = Y_1 - X_1$ 으로부터 X_1 과 Y_1 을 알면 X_2 를 알 수 있기 때문에 (X_1, X_2) 를 (X_1, Y_1) 으로 대체할 수 있다.
- ▶ 마찬가지로, (X_3, X_4) 를 (X_3, Y_2) 로, (X_5, X_6) 를 (X_5, Y_3) 로, (X_7, X_8) 을 (X_7, Y_4) 로 대체할 수 있다.
- ▶ 단, X_1, X_3, X_5, X_7 은 관측이 되지 않는 잠재변수(latent variables)이다. 잠재변수와 Y 를 합하여 $X = (X_1, X_3, X_5, X_7, Y)$ 를 새로운 관측변수로 간주하면 (θ, η) 의 완전 조건부 분포는 디레슈레 분포로 주어진다.
- ▶ 잠재변수 X_1, X_3, X_5, X_7 은 미지의 변수이므로 이들을 모수와 같이 취급하여 깃스 과정에서 표본을추출한다.

Another Example

- ▶ 종합하면, (θ, η) 의 완전 조건부 사후분포를 구해 보면

$$\theta, \eta \mid \mathbf{x} \sim \text{Dirichlet}(x_1 + x_3 + \alpha_1, x_5 + x_7 + \alpha_2, x_9 + \alpha_3)$$

- ▶ 또한 표를 보면 $Y_1 = y_1$ 이 주어졌을때 X_1 은 두요인 중 요인 A_1 의 도수이므로 θ 와 y_1 이 주어졌을 때 X_1 의 조건부 분포는 $B(y_1, \frac{a_1\theta}{a_1\theta+b_1})$ 이다.
- ▶ 마찬가지로 X_3, X_5, X_7 의 조건부분포는

$$X_3 \mid \theta, y_2 \sim B(y_2, \frac{a_2\theta}{a_2\theta+b_2})$$

$$X_5 \mid \eta, y_3 \sim B(y_3, \frac{a_3\eta}{a_3\eta+b_3})$$

$$X_7 \mid \eta, y_4 \sim B(y_4, \frac{a_4\eta}{a_4\eta+b_4}).$$

Another Example

- ▶ 이들 조건부 분포 모두 난수생성이 쉬운 분포이므로 깃스 표본기법을 이용하여 (X_1, X_3, X_5, X_7) 과 (θ, η) 의 표본을 생성할 수 있고, 이 중 (θ, η) 의 표본만 취하면 이들은 $\pi(\theta, \eta | \mathbf{y})$ 를 따르는 사후표본이다.
- ▶ 따라서 깃스 표본기법으로부터 생성된 (θ, η) 의 표본을 사용하여 (θ, η) 에 대한 사후추론을 수행할 수 있다.
- ▶ 다음은 $\mathbf{y} = (14, 1, 1, 1, 5)$ 가

$$\text{Multi} \left(22, \frac{1}{4}\theta + \frac{1}{8}, \frac{1}{4}\theta, \frac{1}{4}\eta, \frac{1}{4}\eta + \frac{3}{8}, \frac{1}{2}(1 - \theta - \eta) \right)$$

로부터의 관측치일 때 $\pi(\theta, \eta) \sim \text{Dirichlet}(1, 1, 1)$ 사전분포를 사용하여 (θ, η) 에 대한 사후추론을 시행하는 깃스표본기법을 적용하자.

Another Example

```
Y=c(14,1,1,1,5); n=22; a=c(0.25,0.25,0.25,0.25)
b=c(0.125,0,0,0.375); c=0.5; alpha=c(1,1,1);
m=1000; N=3000
THETA= matrix(0,m+N,3); X=c(1:9)*0
#Dirichelet generator、
rDirich=function(n,p,a){
  x=matrix(0,n,p)
  for(i in 1:p) x[,i]=rgamma(n,a[i])
  x=x/apply(x,1,sum)
}
#initialize
theta= 0.5; eta=0.5; THETA[1,]= c(theta,eta, 1-theta-eta)
X[1]= 0.5*Y[1]; X[3]= 0.5*Y[2]; X[5]= 0.5*Y[3]
X[7]=0.5*Y[4]; X[9]=Y[5]
```

Another Example

```
#####simulate#####  
for(i in 2:(m+N)){  
  p=3  
  aa=c(X[1]+X[3]+alpha[1],X[5]+X[7]+alpha[2],X[9]+alpha[3])  
  THETA[i,]=rDirich(1,p,aa)  
  theta=THETA[i,1]; eta=THETA[i,2]  
  X[1]=rbinom(1,Y[1], a[1]*theta/(a[1]*theta + b[1]))  
  X[3]=rbinom(1,Y[2], a[2]*theta/(a[2]*theta + b[2]))  
  X[5]=rbinom(1,Y[3], a[3]*eta/(a[3]*eta + b[3]))  
  X[7]=rbinom(1,Y[4], a[4]*eta/(a[4]*eta + b[4]))  
}  
#####End simulation #####  
theta.sim=THETA[ (m+1): (m+N), 1]; eta.sim=THETA[ (m+1): (m+N), 2]  
par(mfrow=c(1,2))  
plot(density(theta.sim), type="l",xlab=expression(theta),  
ylab="posterior",main="")  
plot(density(eta.sim), type="l", xlab=expression(eta), main="")
```

Another Example




Figure: 깃스 표본기법으로부터 추정된 θ, η 의 주변 사후분포

Problem of Gibbs Sampling

- ▶ 깁스표본기법은 각 원소모수의 완전 조건부 사후분포가 표본생성이 용이한 분포여야 한다
- ▶ 즉 각 원소 θ_i 들의 완전 조건부 사후분포 $\pi(\theta_i \mid x, \theta_1, \dots, \theta_{i-1}, \theta_{i+1}, \dots, \theta_p)$ 로부터 직접적인 표본생성이 가능해야 한다.
- ▶ 사전분포가 conjugate prior가 아닌 경우에, 완전 조건부 사후분포로부터 표본추출이 용이하지 않아, 깁스표본기법의 사용이 불가능.

Metropolis-Hastings Algorithm

1. 후보 표본 θ^* 의 추출:

$$\theta^* \sim q(\theta \mid \theta^{(k-1)}).$$

2. 채택확률 계산:

$$\alpha^* = \frac{\pi(\theta^* \mid x)}{\pi(\theta^{(k-1)} \mid x)} \frac{q(\theta^{(k-1)} \mid \theta^*)}{q(\theta^* \mid \theta^{(k-1)})}$$

$$\alpha = \min\{1, \alpha^*\}.$$

3. θ^* 의 채택 또는 기각

$$u \sim U(0, 1),$$
$$\theta^{(k)} = \begin{cases} \theta^* & \text{if } u \leq \alpha, \\ \theta^{(k-1)} & \text{if } u > \alpha. \end{cases}$$

Metropolis Algorithm

- ▶ 후보추출함수 (Sample Generating Density $q(\cdot)$): θ^* 를 추출하기 위해 임의로 선택된 밀도함수.
- ▶ 후보추출함수 $q(\cdot)$ 가 대칭인 경우 **메트로폴리스 알고리즘**이라고 한다.

$$q(\theta^* | \theta^{(k-1)}) = q(\theta^{(k-1)} | \theta^*)$$

- ▶ 채택확률 α^* 이 사후밀도함수의 비가 된다.

$$\alpha^* = \frac{\pi(\theta^* | x)}{\pi(\theta^{(k-1)} | x)}$$

Random Walk Metropolis Algorithm

- ▶ 많은 경우 $q(\cdot)$ 를 정하기 쉽지 않다.
- ▶ 메트로폴리스 알고리즘에서 k 단계의 후보 표본을 현재 표본 $\theta^{(k-1)}$ 을 평균으로 하는 정규분포에서 추출할 경우 이를 랜덤워크(random walk) 메트로폴리스 기법이라고 한다.

$$q(\cdot \mid \theta^{(k-1)}) = N(\theta^{(k-1)}, \delta^2 I).$$

- ▶ δ 값은 랜덤워크의 보폭에 해당
- ▶ δ 가 너무 작으면 높은 자기상관관계로 인해 수렴이 늦어질 수 있다.
- ▶ δ 가 너무 크면 확률이 낮은 영역에서 후보 표본을 추출 할 가능성이 높다.

Properties of Metropolis-Hastings Algorithm

- ▶ 용이한 계산: 채택확률 α^* 의 계산에서 사후밀도함수의 비는 사후밀도함수식의 정규화 상수를 몰라도 계산이 가능.
- ▶ 사후밀도함수의 비:

$$\begin{aligned}\frac{\pi(\theta^* | \mathbf{x})}{\pi(\theta^{(k-1)} | \mathbf{x})} &= \frac{f(\mathbf{x} | \theta^*)\pi(\theta^*)/f(\mathbf{x})}{f(\mathbf{x} | \theta^{(k-1)})\pi(\theta^{(k-1)})/f(\mathbf{x})} \\ &= \frac{f(\mathbf{x} | \theta^*)\pi(\theta^*)}{f(\mathbf{x} | \theta^{(k-1)})\pi(\theta^{(k-1)})}\end{aligned}$$

since

$$\pi(\theta | \mathbf{x}) = f(\mathbf{x} | \theta)\pi(\theta)/f(\mathbf{x})$$

Metropolis-Hastings Algorithm for Multiple Parameters

► Suppose that $\theta = (\theta_1, \theta_2)$. For step k):

(1) $\theta_1^* \sim q_1(\theta_1 \mid \mathbf{x}, \theta_1^{(k-1)}, \theta_2^{(k-1)})$

(2)

$$\alpha_1^* = \frac{\pi(\theta_1^*, \theta_2^{(k-1)} \mid \mathbf{x})}{\pi(\theta_1^{(k-1)}, \theta_2^{(k-1)} \mid \mathbf{x})} \times \frac{q_1(\theta_1^{(k-1)} \mid \theta_1^*, \theta_2^{(k-1)})}{q_1(\theta_1^* \mid \theta_1^{(k-1)}, \theta_2^{(k-1)})}$$
$$\alpha_1 = \min\{1, \alpha_1^*\}$$

(3) $u_1 \sim U(0, 1)$

$$\theta_1^{(k)} = \begin{cases} \theta_1^* & \text{if } u_1 \leq \alpha_1 \\ \theta_1^{(k-1)} & \text{if } u_1 > \alpha_1 \end{cases}$$

Metropolis-Hastings Algorithm for Multiple Parameters

▶ $\theta_2^{(k)}$ 의 추출

(1) $\theta_2^* \sim q_2(\theta_2 \mid \mathbf{x}, \theta_1^{(k)}, \theta_2^{(k-1)})$

(2)

$$\alpha_2^* = \frac{\pi(\theta_1^{(k)}, \theta_2^* \mid \mathbf{x})}{\pi(\theta_1^{(k)}, \theta_2^{(k-1)} \mid \mathbf{x})} \times \frac{q_2(\theta_2^{(k-1)} \mid \theta_1^{(k)}, \theta_2^*)}{q_2(\theta_2^* \mid \theta_1^{(k)}, \theta_2^{(k-1)})}$$
$$\alpha_2 = \min\{1, \alpha_2^*\}$$

(3) $u_2 \sim U(0, 1)$

$$\theta_2^{(k)} = \begin{cases} \theta_2^* & \text{if } u_2 \leq \alpha_2 \\ \theta_2^{(k-1)} & \text{if } u_2 > \alpha_2 \end{cases}$$

Gibbs Sampling vs Metropolis-Hastings Algorithm

- ▶ 깁스 표본기법은 메트로폴리스-헤스팅스 알고리즘의 특수한 경우.
- ▶ 깁스 표본기법에서는 후보추출함수 $q(\cdot)$ 가 각 원소 변수의 완전 조건부 사후밀도함수이다.

$$q_1(\theta_1 \mid \mathbf{x}, \theta_1^{(k-1)}, \theta_2^{(k-1)}) = \pi(\theta_1 \mid \mathbf{x}, \theta_2^{(k-1)})$$
$$q_2(\theta_2 \mid \mathbf{x}, \theta_1^{(k)}, \theta_2^{(k-1)}) = \pi(\theta_2 \mid \mathbf{x}, \theta_1^{(k)})$$

- ▶ 채택확률 α_1^* :

$$\begin{aligned} & \frac{\pi(\theta_1^*, \theta_2^{(k-1)} \mid \mathbf{x})}{\pi(\theta_1^{(k-1)}, \theta_2^{(k-1)} \mid \mathbf{x})} \times \frac{\pi(\theta_1^{(k-1)} \mid \mathbf{x}, \theta_2^{(k-1)})}{\pi(\theta_1^* \mid \mathbf{x}, \theta_2^{(k-1)})} \\ &= \frac{\pi(\theta_1^* \mid \mathbf{x}, \theta_2^{(k-1)})\pi(\theta_2^{(k-1)} \mid \mathbf{x})}{\pi(\theta_1^{(k-1)} \mid \mathbf{x}, \theta_2^{(k-1)})\pi(\theta_2^{(k-1)} \mid \mathbf{x})} \times \frac{\pi(\theta_1^{(k-1)} \mid \mathbf{x}, \theta_2^{(k-1)})}{\pi(\theta_1^* \mid \mathbf{x}, \theta_2^{(k-1)})} \\ &= 1 \end{aligned}$$

Gibbs Sampling vs Metropolis-Hastings Algorithm

- ▶ 마찬가지로 $\alpha_2^* = 1$ 이 되어 항상 $\mathbf{bb}\theta_i^{(k)} = \mathbf{bb}\theta_i^*$ 가 성립한다.
- ▶ 따라서 깁스 표본기법은 메트로폴리스-헤스팅스 기법에서 매번 후보표본 θ^* 를 $\theta^{(k)}$ 로 받아들이며 후보의 채택확률은 1이다.

Metropolis within Gibbs

- ▶ 깃스 표본기법이 메트로폴리스-헤스팅스 기법의 특수한 경우이므로 θ 를 부분적으로 나누어 메트로폴리스-헤스팅스 기법을 적용할 때 θ_2 에 대하여 깃스 표본기법 적용이 가능하다면 θ_2 는 깃스 표본기법을 적용하고 θ_1 은 메트로폴리스-헤스팅스 기법을 적용할 수 있다.
- ▶ 역으로 깃스 표본기법을 적용하는데 일부 원소에서는 완전 조건부 사후분포로부터의 표본생성이 용이하지 않다면 이들 원소에 대해서는 메트로폴리스-헤스팅스 기법을 적용하고 나머지 원소들에 대해서는 깃스 기법을 적용해도 된다.